

Федеральное государственное автономное образовательное учреждение
высшего образования

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Санкт-Петербургская школа экономики и менеджмента

Прикладная статистика

Домашнее задание 4.

Направление 38.03.01 «Экономика»; 38.03.02 «Менеджмент»

Образовательная программа «Международный бакалавриат по бизнесу и
экономике»

ДЗ № 4 выполнили:

Алтышева Жанна БМББЭ2302

Бегитова Кристина БМББЭ2302

Емшанова Евгения БМББЭ2302

Ермакова Екатерина БМББЭ2302

Есина Виктория БМББЭ2302

Казакова Анна БМББЭ2302

Преподаватель:

Т. Л. Журавлева, Доцент НИУ ВШЭ в Санкт-Петербурге,

Санкт-Петербургская школа экономики и менеджмента,

Департамент экономики

Санкт-Петербург

2025

Оглавление

Задание 1: Анализ существующего исследования.....	3
Задание 2: Анализ социально-экономических тенденций с использованием данных RLMS.....	6
Задание 3: Проведение собственного опроса разными методами.....	12
Задание 4: Разработка фальсифицированного исследования.....	30
Источники:.....	37

Задание 1: Анализ существующего исследования

Выберите опубликованное исследование (научная статья, используйте Google Scholar, ResearchGate, например), в котором используется выборочный метод. Ответьте на следующие вопросы:

- Какой метод выборки был использован? (простая случайная, стратифицированная, кластерная и т. д.)
- Почему, по вашему мнению, исследователи выбрали именно этот метод?
- Какие потенциальные ошибки выборки (sampling errors) могут возникнуть в этом исследовании?
- Какие методы могли бы быть лучше в данном случае? Обоснуйте свой ответ.

Описание исследования

11 мая 2022 года в научном журнале ‘Scientific Reports’ было опубликовано исследование «Влияние цифровых медиа на интеллект детей с учетом генетических различий в когнитивных способностях и социально-экономического статуса»[1], проведенное группой ученых из Нидерландов, Германии и Швеции. Целью исследования было изучить влияние различных типов экранного времени (просмотр видео, общение в социальных сетях, видеоигры) на интеллект детей, принимая во внимание генетические предрасположенности и социально-экономический статус. В ходе исследования были выдвинуты две гипотезы:

- 1) Видеоигры могут положительно влиять на интеллект из-за активного вовлечения мозга.
- 2) Просмотр видео и соцсети могут иметь нейтральный или негативный эффект.

Переменные, использованные для исследования, включали оценку интеллекта на основе 5 тестов (по словарному запасу, чтению, памяти, вниманию, пространственному мышлению) и параметр экранного времени по 3 категориям (просмотр видеороликов, соцсети и видеоигры). Переменная оценивалась участниками исследования по шкале, в которой оценки варьировались от ‘не проводил время за экраном’, ‘менее 30 минут’, ‘30 минут’, ‘1 час’, ‘2 часа’, ‘3 часа’ до ‘более 4 часов’. Контрольные переменные – cogPGS (полигенная оценка когнитивных способностей) и SES (социально-экономическое положение, включающее доход семьи, образование родителей, качество района).

[1] Sauce, B., Liebherr, M., Judd, N. *et al.* The impact of digital media on children’s intelligence while controlling for genetic differences in cognition and socioeconomic background. *Sci Rep* 12, 7720 (2022). <https://doi.org/10.1038/s41598-022-11341-2>

Результаты исследования показали, что дети, которые тратили на игры больше времени, чем в среднем большинство участников в выборке, увеличили свой интеллект примерно на 2,5 балла IQ. Усредненно дети тратили два с половиной часа в день на просмотр телевизора, полчаса на социальные сети и один час на видеоигры. Однако от просмотра телевизора или общения в социальных сетях значительного эффекта для интеллекта не наблюдалось как положительного, так и отрицательного.

Выборка взята из исследования ABCD (исследование 'Мозг и когнитивное развитие подростков') – масштабного лонгитюдного исследования в США, в ходе которого в 21 исследовательском центре были собраны данные о биологии, психологии и социальном контексте детей. Выборка состояла из 9855 участников в возрасте 9–10 лет на момент начала исследования и 5169 участников, за которыми наблюдали два года спустя. В исходной выборке насчитывалось 4686 девочек и 5169 мальчиков, медиана составила 9,90 лет, стандартное отклонение = 0,62 года. Конечная выборка включала 2512 девочек и 2657 мальчиков, медиана = 11,92 года, стандартное отклонение = 0,63 года. Выборка для последующего наблюдения намного меньше, чем исходная выборка, поскольку сбор данных по ABCD все на момент исследования еще продолжался, и в выборку для последующего наблюдения в возрасте 11–12 лет вошла только половина от общего числа участников.

Поскольку набор данных ABCD содержит информацию о братьях и сестрах, а также о близнецах, и эта информация могла ошибочно повлиять на дисперсию и снизить точность исследования, то случайным образом был выбран только один участник из каждой семьи.

Анализ метода выборки

В исследовании использован метод стратифицированной случайной выборки (stratified random sampling) – участники набирались через 21 исследовательский центр в США с соблюдением однородных подгрупп по: полу, возрасту и социально-экономическому положению. Внутри стратификации была проведена корректировка для детей из одной семьи – простым случайным методом выбран только один ребенок.

Возможные причины, по которым исследователи выбрали именно метод стратифицированной случайной выборки в том, что данный подход уменьшает ошибку выборки, позволяя получать более точные оценки, а также позволяет проводить сравнения между различными группами. Помимо этого, дети из одной семьи часто имеют схожий стиль воспитания и доступ к гаджетам: случайный выбор одного ребенка снизил риск неточной корреляции в данных.

Однако в исследовании могли произойти потенциальные ошибки выборки. Во-первых, из-за намеренного или случайного искажения участниками

действительного времени, проведенного за экраном, могла произойти систематическая ошибка ответов (response bias). Во-вторых, в исследовании могла возникнуть смещенность из-за отсутствия ответов (non-response bias): после двух лет исследования в выборку для последующего наблюдения в возрасте 11–12 лет вошла только половина от общего числа участников.

Помимо этого, на результаты исследования могли повлиять ошибки, не связанные с процессом выборки. Так, данные, взятые из исследования ABCD, собирались в 2017–2022 гг.: карантин мог увеличить экранное время и повлиять на когнитивное развитие детей, что могло привести к неточным выводам. Также учеными не учитывался тип игр, в который играли участники исследования — это тоже могло привести к неточным результатам, так как разные жанры игр могут по-разному воздействовать мозговую активность детей.

В данном исследовании использование стратифицированной случайной выборки более оправдано, чем применение других методов. Например, квотная выборка также предполагает деление участников на подгруппы по схожим признакам, однако она требует субъективных решений исследователей при заполнении квот и при данном методе отбора невозможно рассчитать точные стандартные ошибки для сравнения групп. Это делает статистические тесты менее надежными. Для повышения точности результатов исследования можно отслеживать данные по потраченному экранному времени на основе информации с устройств, на которых участники играли и просматривали видео. Также добавление классификации игр по жанрам может быть полезно для исследования влияния определенных типов игр на мозг и интеллект детей.

Задание 2: Анализ социально-экономических тенденций с использованием данных RLMS

- Ознакомьтесь с методом выборки RLMS на сайте <https://www.hse.ru/en/rlms/sampling> и определите, к какому типу выборки он относится.

Метод выборки в RLMS (Russia Longitudinal Monitoring Survey — Российский мониторинг экономического положения и здоровья населения) относится к многоступенчатой стратифицированной вероятностной выборке (multistage stratified probability sampling)[1].

Ключевые особенности выборки RLMS:

1. Стратификация – выборка стратифицирована по регионам (географическим и социально-экономическим критериям).
 2. Многоступенчатость – отбор происходит в несколько этапов:
 - 2.1. Сначала выбираются первичные единицы отбора (например, районы или населенные пункты).
 - 2.2. Затем отбираются домохозяйства внутри этих единиц.
 - 2.3. Наконец, внутри домохозяйств могут опрашиваться все взрослые члены или выборочно.
 3. Вероятностный метод – на каждом этапе используется случайный отбор, что позволяет минимизировать смещения.
- Выберите социально-экономическую тему исследования, связанную с Россией.

Исследовательский вопрос:

“Ухудшилось ли психическое здоровье населения России после начала специальной военной операции?”

Начало специальной военной операции (СВО) в феврале 2022 года стало катализатором комплексного кризиса, затронувшего не только экономику, но и психическое здоровье россиян. Этот феномен требует глубокого изучения, так как сочетает в себе уникальные социально-экономические и психологические факторы. Масштаб психологического стресса, вызванного геополитической нестабильностью, санкционным давлением и мобилизацией, сильно увеличился.

Также можно предположить, что причиной возможного ухудшения психического состояния стала “информационная тревога” — постоянное воздействие противоречивых новостей, усиленное цифровизацией медиaprостранства.

Экономические факторы усугубляют ситуацию. Санкции 2022 года спровоцировали инфляцию (17.8% в пиковый период), снижение реальных доходов (на 1%) и переориентацию торговых потоков, что повысило транзакционные издержки для

бизнеса[2]. Для населения это вылилось в сберегательное поведение — доля расходов домохозяйств в ВВП сократилась с 49.2% до 46.9%, что свидетельствует о страхе перед будущим[2]. Такой перекося усиливает социальное неравенство, которое коррелирует с риском депрессивных расстройств.

В исследовании предлагается, помимо изучения общей тенденции, также проверить, какая возрастная группа людей испытала более сильные изменения. Рекомендуется разделить возрастные группы следующим образом:

1. 18 - 33 — с 18 лет в России наступает полная гражданская дееспособность, что делает эту группу юридически самостоятельной в принятии решений (включая участие в опросах), потенциально затрагиваемой мобилизационными мероприятиями, а также обладающей когнитивной и эмоциональной зрелостью.
2. 34 - 62 — пик профессиональной карьеры и доходов, ответственность за родителей и детей, максимальная социальная нагрузка.
3. 63+ — зависимость от государственных выплат и помощи родных, ограниченные возможности к адаптации.

При изучении влияния специальной военной операции на психическое состояние населения принципиально важно учитывать гендерное разделение, поскольку мужчины и женщины подвергаются принципиально разным видам психологической нагрузки. Традиционное представление о большей эмоциональной уязвимости женщин в данном контексте требует существенной корректировки, так как мужское население оказалось под комплексным давлением. Основное различие в данном случае то, что мужчины подвергаются более прямому давлению, мобилизационная угроза, социальное давление, в то время как женщины испытывают больше косвенное давление, тревога за близких.

Крайне важно вовремя отследить психологический кризис в обществе, и запустить механизмы для его устранения: интеграцию психологической поддержки в трудовые программы, мониторинг психического здоровья в наиболее пострадавших отраслях и регионах, а также адаптацию образовательных программ для молодежи.

- Определите, за какие годы вы будете использовать данные RLMS для анализа, и обоснуйте свой выбор.

Для проведения исследования стоит выбрать период с 2021 по 2023 год. Этот временной отрезок охватывает ключевые этапы кризиса: от предшествующей стабилизации до острого шока и последующей адаптации, что делает его подходящим для анализа долгосрочных эффектов.

2021 год служит важной контрольной точкой. Это период постковидного восстановления, когда экономика демонстрировала рост, а психическое здоровье населения начало возвращаться к докризисным показателям после пандемии. Данные за этот год позволяют отделить последствия COVID-19 от эффектов СВО, начавшейся в феврале 2022 года.

2022 год представляет собой фазу острого кризиса. Санкции, мобилизация и геополитическая нестабильность создали беспрецедентное давление на психику россиян. В этот период фиксировались резкий рост продаж антидепрессантов (на 87%), увеличение обращений за психологической помощью и всплеск симптомов депрессии, особенно среди молодежи[3]. Исследование этого года позволяет оценить непосредственную реакцию населения на шоковые события, включая изменения в поведении и эмоциональном состоянии.

2023 год отражает этап адаптации к новым реалиям. К этому времени проявились долгосрочные эффекты: структурные изменения в экономике (переориентация на военно промышленный комплекс, рост инфляции), накопленная усталость от информационного стресса и социальные последствия мобилизации. Данные за этот период особенно ценны для анализа устойчивости психического здоровья в условиях продолжительного кризиса. Например, исследования отмечают рост ПТСР у военных СВО и их семей, также как и усиление социального неравенства, что коррелирует с ухудшением психического состояния уязвимых групп .

Таким образом, период 2021–2023 годов предоставляет уникальную возможность для комплексного анализа: от "до"- и "после"-кризисных сравнений до изучения механизмов адаптации. Это позволяет не только констатировать изменения, но и разрабатывать адресные меры поддержки для наиболее уязвимых групп населения.

- Составьте список ключевых переменных RLMS.

Данные необходимые по каждому году (2021-2023 гг.):

1. Возраст
2. Пол
3. Ответ на вопрос 131 раздела М (раздел “Оценка здоровья”)
4. Ответы на вопросы 131 раздела L (раздел “Медицинское обслуживание”)
5. Ответ на вопрос 586.7 раздела J (раздел “Работа”) с 2022 года

Рисунок 1. Вопрос 131 раздела М (раздел “Оценка здоровья”)

21(131). В течение последних 12 месяцев у Вас были серьёзные нервные расстройства, депрессии?	
AAM131	Да 1
	Нет 2
	З/О 7
	ОТКАЗ 8

Рисунок 2. Вопросы 131 раздела L (раздел “Медицинское обслуживание”)

22(131). А теперь при ответе на несколько следующих вопросов, я попрошу Вас заполнить вопросник самостоятельно в моем присутствии. Прочтите, пожалуйста, внимательно до конца каждый вопрос, подумайте и выберите тот ответ, который соответствует Вашему мнению, затем обведите кружком соответствующую ему цифру. Если какой-нибудь вопрос покажется Вам слишком личным, и Вы не захотите на него отвечать, пропустите его и переходите к следующему. Когда закончите отвечать, передайте, пожалуйста, вопросник мне, и мы перейдем к другой теме.
ИНТЕРВЬЮЕР! ПЕРЕДАЙТЕ ВОПРОСНИК РЕСПОНДЕНТУ.]

Скажите, пожалуйста, для Вас характерны следующие проблемы...?

	Да	Нет	3/0	ОТКАЗ
AAI131.1. Частая нервозность	1	2	7	8
AAI131.2. Чувство тревоги, частые приступы паники	1	2	7	8
AAI131.3. Приступы раздраженности, агрессии	1	2	7	8
AAI131.4. Хроническая бессонница	1	2	7	8
AAI131.5. Ослабление памяти	1	2	7	8
AAI131.6. Периодическая депрессия	1	2	7	8
AAI131.7. Другие расстройства психики	1	2	7	8

Рисунок 3. Вопрос 586.7 раздела J (раздел “Работа”) с 2022 года

183(586). Можете ли Вы сказать, что после февраля 2022 года...?

	Да	Нет	3/0	ОТКАЗ
AAJ586.1. Вам пришлось экономить на продуктах питания	1	2	7	8
AAJ586.2. Вы не смогли купить нужные лекарства	1	2	7	8
AAJ586.3. Вам пришлось отказаться от запланированной покупки недвижимости или машины	1	2	7	8
AAJ586.4. Вам пришлось отказаться от запланированной покупки бытовой техники, электроники	1	2	7	8
AAJ586.5. Вы начали пить или стали больше пить алкоголя	1	2	7	8
AAJ586.6. Вы стали реже ходить в кино, театр и т.п.	1	2	7	8
AAJ586.7. У Вас появилось чувство тревоги	1	2	7	8
AAJ586.8. Вы не смогли выплатить взнос за кредит	1	2	7	8
AAJ586.9. Вы не смогли поехать отдохнуть	1	2	7	8
AAJ586.10. Ваши сбережения или активы оказались «заморожены»	1	2	7	8

Таким образом, получаем 9 переменных, на основе которых можно будет максимально посмотреть возможные аспекты изменения психического состояния населения, разделив их по возрастным группам и полу.

- Опишите план анализа данных.

Для того чтобы исследовать влияние СВО на психическое состояние граждан РФ, сначала необходимо скачать данные за 2021-2023 гг. с базы данных репрезентативных выборок и расшифровать их в R. Следующим этапом отбираем необходимые переменные каждого года (2022 – вопросы 131 раздела М и 131 раздела L, пол и возраст, 2023-2024 – все вопросы) и создаем для каждого датафрейм, при этом очищая каждый от ненужных значений, а именно для всех вопросов удаляем возможно возникающие экспоненциальные значения и кодировки ответов на вопросы 7 и 8 (7 – 3/О, 8 – Отказ), так как они не содержат полезной информации для анализа психического здоровья и могут исказить результаты в последующем анализируемых долей, уменьшив долю каждого имеющего полезную информацию ответа. Также убираем ответы на вопросы респондентов младше 18 лет, так как у взрослого населения психика считается более сформированной, нежели у детей и подростков.

Далее переходим к самому анализу показателей. Для этого будет использоваться Z-тест разницы между двумя долями генеральных совокупностей и построение доверительных интервалов для сравнения долей двух генеральных совокупностей. Для того чтобы посмотреть тенденцию, сначала будут сравниваться доли 2022 года с 2021 по всем переменным кроме вопроса 586.7 раздела J (его не было в 2021 году), а потом доли 2023 г. с 2022 г. по всем переменным. Каждое сравнение будет делиться на сравнение долей по все выборке по каждой переменной, потом сравнение по возрастным группам, а потом для каждой возрастной группе будут сравниваться доли по полу. Для каждого сравнения будет проводится такие этапы:

1. Фильтрация данных (при сравнении по полу/возрасту).
2. Расчет необходимых показателей (доля исследуемой выборки, ответившая “Да” двух годов; объем каждой выборки; совокупную долю по двум годам).
3. Нахождение критических значений для 10%, 5% и 1% уровней значимости ($z_{\alpha/2}$).
4. Расчет и построение доверительного интервала по формуле

$$P1 - P2 \pm z_{\alpha/2} \times \sqrt{\frac{P1(1-P1)}{n1} + \frac{P2(1-P2)}{n2}}$$
, где $P1, P2$ – доли выборок за два года, $n1, n2$ – объемы выборок двух годов, $z_{\alpha/2}$ – критические значения для 10%, 5% и 1% уровней значимости.

5. Проведение анализа полученных интервалов и их интерпретация.
6. Расчет критических значений $z_{0,1}, z_{0,05}, z_{0,01}$.
7. Проведение проверки гипотез $H_0: \pi_1 = \pi_2$ и $H_1: \pi_1 < \pi_2$, рассчитывая тестовую статистику по формуле.

$$Z = \frac{P1 - P2 - (\pi_1 - \pi_2)}{\sqrt{P(1-P)(\frac{1}{n1} + \frac{1}{n2})}}$$
, где $P1, P2$ – доли выборок за два года, π_1, π_2 – доли генеральных совокупностей, P – совокупная доля по двум годам, $n1, n2$ – объемы выборок двух годов.

8. Сравнение тестовой статистики с критическими значениями $z_{0,1}, z_{0,05}, z_{0,01}$.
9. Проведение анализа полученных результатов и их интерпретация.

Стоит отметить, если на этапе построения доверительных интервалов получилось, что он включает ноль, то это будет означать, что статистически значимого изменения в доли по переменной нет, и следовательно не будет необходимости проводить последующий анализ.

- Рассмотрите возможные ограничения использования данных RLMS в вашем исследовании.

Одно из ограничений, с которым мы столкнулись, это то, что при скачивании данных из открытого доступа, некоторые из переменных, которые необходимо проанализировать отсутствуют, то есть данных по этим вопросам в открытом доступе нет, возможно, из-за того, что вопросы затрагивают достаточно чувствительные темы и RLMS старается усилить анонимизацию. Однако, эту проблему можно решить, запросив доступ к микроданным RLMS, обосновав научную значимость исследования и проведения всех необходимых процедур, связанных с конфиденциальностью информации.

Также при должном получении данных есть риск возникновения смещения ответов из-за того, что респонденты могут искажать оценку своего психологического состояния (переоценивать или недооценивать). Помимо этого есть вероятность того, что люди с психическими расстройствами чаще прекращают повторное участие в опросах, что тоже может влиять на смещение. Более того, есть и вероятность возникновения смещенности из-за собственных взглядов и убеждений интервьюера.

Стоит отметить, что из-за чувствительности вопросов деление выборок на возрастные группы, а потом по полу может привести к небольшому количеству ответов, так как политическая обстановка и и иные факторы могут влиять на выбор респондентов не отвечать на данные вопросы, уменьшая тем самым исследуемую выборку. Такая проблема значит, что мощность теста будет низкой, а следовательно появляется высокий риск, что тест неправильно отвергнет ложную нулевую гипотезу, что приведет к формулировке некорректных выводов либо упущению потенциально значимых эффектов.

Возможно также возникновение проблемы с репрезентативностью выборки, хоть и используются репрезентативные данные, но все равно данные RLMS могут не отражать состояние психического здоровья ключевых групп населения, наиболее уязвимых к последствиям СВО, таких как беженцы и внутренне перемещенные лица, мобилизованные и их семьи, а также жители новых территорий РФ.

Задание 3: Проведение собственного опроса разными методами

1. Сформулируйте интересующий вас исследовательский вопрос. Проще всего проводить опрос среди студентов, так как это легкодоступная целевая аудитория (например, "Как студенты оценивают качество онлайн-обучения?").

В последние годы на федеральном уровне ведутся темы о повышении рождаемости в России. Одной из ключевых обсуждаемых проблем является то, что представители поколения Z¹ придают больше значения личной свободе и карьерному росту, нежели чем традиционным ценностям. Кроме того, в условиях экономической нестабильности и высоких затрат зумеры принимают решение о рождении меньшего количества детей или о более позднем их рождении, либо вообще отказываются становиться родителями. Также, одной из причин нежелания зумеров заводить детей является наличие негативного опыта в их собственных семьях, где они были детьми (например, неблагоприятная финансовая ситуация в многодетных семьях).

В связи с данными обсуждениями, мы решили провести исследование, направленное на то, чтобы определить, влияет ли количество детей в семьях, где выросли респонденты, на количество детей, которые они хотят завести в собственной семье. Также, мы проверим, равно ли желаемое количество детей у мужчин и женщин. Таким образом, в ходе нашей работы мы:

- используем тест хи-квадрат на ассоциацию (независимость) для проверки наличия взаимосвязи между количеством детей в семьях зумеров и их желанием иметь многодетную семью;
- построим доверительные интервалы для сравнения средних значений желаемого количества детей в каждой выборке;
- проверим гипотезу о равенстве желаемого количества детей у мужчин и женщин.

Исследовательский вопрос: "Как количество детей в семьях, в которых выросли зумеры, влияет на их предпочтения относительно желаемого количества детей в собственной семье?"

2. Выберите три различных метода выборки (например, случайная выборка, квотная выборка, удобная выборка).

Для проведения опроса нами было выбрано три различных метода выборки:

1. Случайная выборка: лица в возрасте от 18 до 27 лет (рассылка в различные каналы и группы, за исключением общего чата университета и лиц квотных выборок).
2. Удобная выборка: лица в возрасте от 17 до 24 лет (рассылка в общие чаты студентов Высшей школы экономики).

¹ Поколение Z, также известное как зумеры, - это люди, родившиеся между 1997 и 2012 годами.

3. Квотная выборка: лица мужского и женского пола в возрасте от 15 до 27 лет (рассылка друзьям и знакомым в различные каналы общения, за исключением лиц из случайной и удобной выборок).

Опрос состоял из следующих вопросов:

1. Ваш возраст;
2. Ваш пол;
3. Сколько детей в Вашей семье, включая Вас?
4. Сколько детей Вы бы хотели иметь?

3. Соберите не менее 20 ответов, используя каждый метод.

Результаты опроса²:

1. Случайная выборка: 33 респондента, из них 23 - женщины, 10 - мужчины
 2. Удобная выборка: 35 респондентов, из них 26 - женщины, 9 - мужчины
 3. Квотная выборка (женщины): 33 респондента
 4. Квотная выборка (мужчины): 31 респондент
4. Сравните результаты, используя статистические методы, рассмотренные в курсе:
 - Есть ли различия?
 - Почему?
 - Какой метод предоставил наиболее репрезентативные данные?

По результатам опроса диапазоны желаемого количества детей в разных выборках составили:

Случайная выборка - от 0 до 10

Удобная выборка - 0 до 4

Квотная выборка (женщины) - от 0 до 3

Квотная выборка (мужчины) - от 0 до 7

По результатам опроса диапазоны количества детей в семьях зумеров составили:

Случайная выборка - от 1 до 5

Удобная выборка - от 1 до 4

Квотная выборка (женщины) - от 1 до 4

Квотная выборка (мужчины) - от 1 до 5

Анализ на независимость

Для выявления взаимосвязи между количеством детей в семьях зумеров и их желанием иметь многодетную семью, мы провели тест хи-квадрат на ассоциацию.

²  Результаты опроса

H_0 : **нет связи между** количеством детей в семьях зумеров и их желанием иметь многодетную семью.

H_1 : **есть связь между** количеством детей в семьях зумеров и их желанием иметь многодетную семью.

Для проверки гипотезы мы построили таблицы сопряженности в R, посчитали значения хи-квадрат для каждой из выборок и критические значения для уровней значимости 0,05 и 0,01. Скрипт кода для статистического анализа хи-квадрат на ассоциацию представлен ниже.

```
library(readxl)
# Запуск цикла для чтения каждого из 4 листов с выборками
for (sample in c(
  'Случайная выборка',
  'Удобная выборка',
  'Квотная выборка (женщины)',
  'Квотная выборка (мужчины)'
)) {
  # Чтение листа
  df = read_excel(
    path='/Users/gene/Desktop/Хи-квадрат на независимость.xlsx',
    sheet=sample
  )
  # Построение таблицы сопряженности
  conjugacy_table = table(df$`Тип семьи респондента`, df$`Тип желаемой
семьи`)
  show(conjugacy_table)
  # Расчет числа степеней свободы
  ndf = ((nrow(conjugacy_table)) - 1) * ((ncol(conjugacy_table)) - 1)
  # Расчет значения хи-квадрат для выборки
  x = chisq.test(conjugacy_table)$statistic
  # Расчет критического значения с уровнем значимости 0.05
  cr_value_1 = qchisq(0.95, ndf)
  # Расчет критического значения с уровнем значимости 0.01
  cr_value_2 = qchisq(0.99, ndf)
  print(sample)
  print('Значение хи-квадрат')
  print(x)
  print('Критическое значение с уровнем значимости 0.05')
  print(cr_value_1)
  print('Критическое значение с уровнем значимости 0.01')
  print(cr_value_2)
}
```

В таблицах сопряженности строки представляют тип семьи респондента (многодетная или не многодетная), а столбцы - тип желаемой семьи (многодетная, не многодетная, нет детей).

1. Тест хи-квадрат для случайной выборки

Таблица сопряженности для случайной выборки представлена ниже.

Таблица 1. Таблица сопряженности для случайной выборки.

	Многодетная семья	Не многодетная семья	Нет детей
Многодетная	4	4	1
Не многодетная	2	20	2

Значение хи квадрат для случайной выборки составило 6,11.

Критическое значение с уровнем значимости 5% для случайной выборки составило 5,99.

Критическое значение с уровнем значимости 1% для случайной выборки составило 9,21.

Вывод: так как $9,21 > 6,11 > 5,99$, то нулевая гипотеза не отклоняется на уровне значимости 1%, то есть для данного уровня значимости у нас недостаточно статистических доказательств того, что есть связь между двумя категориальными переменными (типом семьи респондента и типом желаемой семьи). Следует учесть, что объем выборки небольшой ($n = 33$), что снижает мощность теста и не дает возможности уверенно сказать, что взаимосвязи между переменными нет. Тем не менее, мы отклоняем нулевую гипотезу на уровне значимости 5%, т.е. у нас есть убедительные доказательства связи между количеством детей в семьях зумеров (типом семьи: многодетная или не многодетная) и желанием иметь многодетную семью.

Интерпретация таблицы сопряженности: из таблицы сопряженности видно, что большинство респондентов из не многодетных семей (20 из 24) хотят иметь 1-2 ребенка, в то время как респонденты, которые выросли в многодетных семьях, в равной степени хотят иметь как 1-2 ребенка (4 из 9), так и от 3-х и более детей (4 из 9), и всего 1 респондент из многодетной семьи не хочет иметь детей. Также заметим, что не хотят детей в своем большинстве те респонденты, которые выросли в не многодетных семьях. Кроме того, многодетную семью хотят иметь 6 из 33 опрошенных зумеров, причем 4 из них выросли в многодетных семьях. Таким образом, мы наблюдаем определенную взаимосвязь между типом семьи респондентов и типом желаемой семьи: в основном от 3-х и более детей хотят респонденты из многодетных семей, а зумеры, которые выросли в семье, где было 1-2 ребенка, так же хотят иметь не более 2-х детей.

2. Тест хи-квадрат для удобной выборки

Таблица сопряженности для удобной выборки представлена ниже.

Таблица 2. Таблица сопряженности для удобной выборки.

	Многодетная семья	Не многодетная семья	Нет детей
Многодетная	4	7	1
Не многодетная	8	14	1

Значение хи квадрат для удобной выборки составило 0,23.

Критическое значение с уровнем значимости 5% для случайной выборки составило 5,99.

Критическое значение с уровнем значимости 1% для случайной выборки составило 9,21.

Вывод: так как $9,21 > 5,99 > 0,23$, то нулевая гипотеза не отклоняется на всех уровнях значимости, то есть у нас недостаточно статистических доказательств того, что есть связь между двумя категориальными переменными. Следует учесть, что объем выборки небольшой ($n = 35$), что снижает мощность теста и не дает возможность уверенно сказать, что взаимосвязи между переменными нет.

Интерпретация таблицы сопряженности: посмотрев на таблицу сопряженности, можно сделать вывод, что большинство респондентов как из многодетной семьи (7 из 12), так и из не многодетной семьи (14 из 23) хотят иметь 1-2 ребенка в собственных семьях. Также, многодетную семью хотят иметь 12 из 35 опрошенных зумеров, причем 8 из них выросли в не многодетных семьях (возможно, это связано с тем, что респонденты, выросшие в многодетных семьях, на примере своей семьи понимают, что иметь 3 ребенка - слишком много для них). Кроме того, не иметь детей в равной степени хотят как респонденты из многодетных, так и из не многодетных семей. Таким образом, мы не наблюдаем определенной зависимости между типом семьи респондентов и количеством детей, которые они хотят иметь в собственной семье.

3. Тест хи-квадрат для квотной выборки (женщины)

Таблица сопряженности для квотной выборки (женщины) представлена ниже.

Таблица 3. Таблица сопряженности для квотной выборки (женщины).

	Многодетная семья	Не многодетная семья	Нет детей
Многодетная	2	5	0
Не многодетная	2	22	2

Значение хи квадрат для квотной выборки (женщины) составило 2,64.

Критическое значение с уровнем значимости 5% для случайной выборки составило 5,99.

Критическое значение с уровнем значимости 1% для случайной выборки составило 9,21.

Вывод: так как $9,21 > 5,99 > 2,64$, то нулевая гипотеза не отклоняется на всех уровнях значимости, то есть у нас недостаточно статистических доказательств того,

что есть связь между двумя категориальными переменными. Следует учесть, что объем выборки небольшой ($n = 33$), что снижает мощность теста и не дает возможность уверенно сказать, что взаимосвязи между переменными нет.

Интерпретация таблицы сопряженности: согласно таблице сопряженности, как и в случае удобной выборки, большинство респондентов как из многодетной семьи (5 из 7), так и из не многодетной семьи (22 из 26) хотят иметь 1-2 ребенка в собственных семьях. Иметь от 3-х и более детей хотят в равной степени респонденты из многодетных (2 из 4) и не многодетных (2 из 4) семей. Респонденты, которые не хотят иметь детей, выросли в не многодетных семьях. Таким образом, мы могли бы наблюдать определенную взаимосвязь лишь в том случае, если бы большинство респондентов из многодетных семей хотели иметь от 3-х и более детей в собственных семьях, однако в нашем случае мы такой взаимосвязи не наблюдаем. Опять же, стоит учесть маленький объем выборки, который не позволяет получить более репрезентативный результат.

4. Тест хи-квадрат для квотной выборки (мужчины)

Таблица 4. Таблица сопряженности для квотной выборки (мужчины).

	Многодетная семья	Не многодетная семья	Нет детей
Многодетная	2	7	0
Не многодетная	4	17	1

Значение хи квадрат для квотной выборки (мужчины) составило 0,46.

Критическое значение с уровнем значимости 5% для случайной выборки составило 5,99.

Критическое значение с уровнем значимости 1% для случайной выборки составило 9,21.

Вывод: так как $9,21 > 5,99 > 0,46$, то нулевая гипотеза не отклоняется на всех уровнях значимости, то есть у нас недостаточно статистических доказательств того, что есть связь между двумя категориальными переменными. Следует учесть, что объем выборки небольшой ($n = 31$), что снижает мощность теста и не дает возможность уверенно сказать, что взаимосвязи между переменными нет.

Интерпретация таблицы сопряженности: как в случае удобной выборки и квотной выборки (женщины), большинство респондентов (24 из 31) хотят иметь 1-2 ребенка в собственных семьях: из них 7 из 9 респондентов, выросших в многодетных семьях, и 17 из 22 респондентов, которые выросли в семье, где было 1-2 ребенка. Многодетную семью хотят иметь 6 из опрошенных мужчин, причем 4 из них выросли в не многодетных семьях. Таким образом, мы снова не наблюдаем определенной взаимосвязи между переменными, причиной чего может быть небольшой объемом выборки ($n = 31$).

Вывод о различиях в результатах: отметим, что практически равный объем каждой выборки небольшой (от 31 до 35), что снижает мощность теста и не позволяет

получить репрезентативный результат. Тем не менее, в проведенном статистическом анализе нулевая гипотеза о том, что нет взаимосвязи между количеством детей в семьях респондентов и желанием иметь многодетную семью, была отвергнута только на данных случайной выборки на уровне значимости 5% (гипотеза не была отвергнута на уровне значимости 1%), что объясняется следующим: случайная выборка формируется случайным образом из всей популяции, что обеспечивает её репрезентативность и уменьшает систематические смещения, в то время как удобная выборка отбирается на основе доступности и удобства сбора результатов, что может привести к смещению результатов и не полному отражению всей популяции. Квотная выборка, в свою очередь, формируется с учетом определенных характеристик, что помогает обеспечить пропорциональное представление групп, но при этом может иметь свои особенности, например, разное отношение мужчин и женщин в вопросе рождения детей. Также, важно отметить тот факт, что в небольших выборках (около 30 человек) случайные колебания могут существенно влиять на результаты теста хи-квадрат, что и приводит к различию в результатах между случайной и остальными типами выборок. В любом случае, в нашем исследовании результаты были примерно одинаковы (нулевая гипотеза была отвергнута лишь в случайной выборке на уровне значимости 5%, причина такого результата описана выше).

Таким образом, наиболее репрезентативные данные предоставил метод случайной выборки, поскольку она формируется из всей популяции, что обеспечивает лучшую репрезентативность и снижает риск возникновения систематических смещений.

Желаемое количество детей в семьях представителей поколения Z

Желаемое количество детей по данным случайной выборки представлено в виде вектора:

```
children_random <- c(1, 1, 2, 3, 1, 2, 0, 2, 2, 5, 2, 2, 1, 2, 0, 2, 1, 10, 2, 2, 3, 2, 1, 0, 4, 2, 2, 2, 1, 2, 5, 2, 2)
```

Рассчитаем среднее значение, дисперсию и стандартное отклонение выборки:

```
> # Вычисление среднего
> mean(children_random)
[1] 2.151515
> # Вычисление дисперсии
> var(children_random)
[1] 3.320076
> # Вычисление стандартного отклонения
> sd(children_random)
[1] 1.822108
```

Желаемое количество детей по данным удобной выборки представлено в виде вектора:

```
children_conv <- c(4, 1, 2, 3, 2, 0, 2, 4, 3, 3, 2, 2, 2, 1, 2, 3, 2, 3, 1, 2, 1, 0, 2, 2, 3, 4, 3, 2, 2, 1, 3, 2, 3, 1, 2)
```

Рассчитаем среднее значение, дисперсию и стандартное отклонение выборки:

```
> # Вычисление среднего
> mean(children_conv)
[1] 2.142857
> # Вычисление дисперсии
> var(children_conv)
[1] 1.008403
> # Вычисление стандартного отклонения
> sd(children_conv)
[1] 1.004193
```

Желаемое количество детей по данным квотной выборки (женщины) представлено в виде вектора:

```
quota_women <- c(2, 1, 2, 2, 2, 1, 2, 2, 2, 2, 1, 2, 3, 0, 2, 2, 1, 2, 2, 3, 2, 1, 1, 1, 2, 2, 2, 0, 3, 1, 3, 2, 1)
```

Рассчитаем среднее значение, дисперсию и стандартное отклонение выборки:

```
> # Вычисление среднего
> mean(quota_women)
[1] 1.727273
> # Вычисление дисперсии
> var(quota_women)
[1] 0.5795455
> # Вычисление стандартного отклонения
> sd(quota_women)
[1] 0.7612788
```

Желаемое количество детей по данным квотной выборки (мужчины) представлено в виде вектора:

```
quota_men <- c(2, 0, 3, 2, 1, 2, 2, 1, 1, 2, 1, 2, 2, 1, 1, 1, 2, 1, 3, 3, 4, 7, 2, 1, 1, 4, 1, 2, 1, 2, 1)
```

Рассчитаем среднее значение, дисперсию и стандартное отклонение выборки:

```
> # Вычисление среднего
> mean(quota_men)
[1] 1.903226
> # Вычисление дисперсии
> var(quota_men)
[1] 1.756989
```


```
> # Вычисление стандартного отклонения
> sd(quota_men)
[1] 1.325515
```

При помощи боксплотов визуально представим распределение желаемого количества детей по четырем выборкам.

```
library(ggplot2)
data <- data.frame(
  group = rep(c("Случайная", "Удобная", "Квотная (ж)", "Квотная (м)"),
    times = c(33, 35, 33, 31)),
  values = c(children_random, children_conv, quota_women, quota_men)
)

# Boxplot
ggplot(data, aes(x = group, y = values, fill = group)) +
  geom_boxplot() +
  labs(title = "Распределение желаемого количества детей по выборкам",
    y = "Желаемое кол-во детей", x = "") +
  theme_minimal()
```

Рисунок 4. Сравнение распределения желаемого количества детей по четырем выборкам в виде ящиков с усами.



Из полученных графиков с распределением желаемого количества детей в выборках, видим, что во всех выборках наблюдается правосторонняя асимметрия (большинство респондентов указывают 1-2 ребенка). Присутствуют единичные выбросы с высокими значениями (один выброс в удобной выборке (0 детей) два выброса в квотной выборке по мужчинам, и три выброса в случайной выборке, максимальный выброс - 10 детей в случайной выборке). Визуально распределения по четырем выборкам выглядят схожими. В целом, графики подтверждают общий тренд поколения Z к малодетности, но с сохранением вариативности репродуктивных установок.

Поскольку размеры выборок достаточно велики (>30), мы заменяем неизвестные дисперсии генеральных совокупностей соответствующими дисперсиями выборки. Также по этой же причине мы используем стандартные нормальные значения для доверительных интервалов.

Для выявления различий между результатами построим доверительные интервалы с разными уровнями значимости - 90%, 95% и 99% - для сравнения средних значений желаемого количества детей. Воспользуемся следующей формулой:

Рисунок 5. Формула для расчета доверительных интервалов для разницы независимых выборок при неизвестных дисперсиях генеральной совокупности

Если σ_1^2 и σ_2^2 неизвестны, и n_1 и n_2 велики (> 30), то $100(1 - \alpha)\%$ доверительный интервал для $\mu_1 - \mu_2$ будет таким:

$$\bar{x}_1 - \bar{x}_2 \pm z_{\alpha/2} \times \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

где $z_{\alpha/2}$ - критическое значение из стандартного нормального распределения.

Критические значения z:

90% ДИ: $z = 1.645$

95% ДИ: $z = 1.960$

99% ДИ: $z = 2.576$

Построим 4 доверительных интервалы для сравнения средних значений:

1. Случайной выборки и квотной выборки (женщины)

Разница средних случайной выборки и квотной выборки (женщины):

$2,15 - 1,73 = 0,42$

```
> se1 <-
sqrt((var(children_random))^2/length(children_random)+(var(quota_women))
^2/length(quota_women))
> se1
[1] 0.5866902
```

```
z_90 <- 1.645
z_95 <- 1.960
z_99 <- 2.576
```

```
di1_90 <- 0.42 + c(-1, 1)*z_90*se1
di1_95 <- 0.42 + c(-1, 1)*z_95*se1
di1_99 <- 0.42 + c(-1, 1)*z_99*se1
data.frame(
  Уровень_доверия = c("90%", "95%", "99%"),
  Нижняя_граница = c(di1_90[1], di1_95[1], di1_99[1]),
  Верхняя_граница = c(di1_90[2], di1_95[2], di1_99[2])
)
```

Результат вывода данного кода:

	Уровень_доверия	Нижняя_граница	Верхняя_граница
1	90%	-0.5451053	1.385105
2	95%	-0.7299127	1.569913
3	99%	-1.0913138	1.931314

Интерпретация результатов: на всех уровнях значимости (90%, 95% и 99%) имеется широкий диапазон интервалов (особенно на 99% уровне), что указывает на большую неопределенность в оценке истинной разницы и влияние выбросов в данных (особенно в случайной выборке, где есть значения 10 и 5 детей). Также на полученные результаты влияет ограниченная мощность исследования из-за небольших размеров выборок. Так как все полученные интервалы включают ноль, это может указывать на то, что различия между группами не являются статистически значимыми. Полученные данные не предоставляют достаточных доказательств для утверждения о существовании различий в желаемом количестве детей между случайной выборкой и квотной выборкой женщин на любом стандартном уровне значимости.

2. Случайной выборки и удобной выборки

Разница средних случайной выборки и удобной выборки: $2,15 - 2,14 = 0,01$

```
> se2 <-
sqrt((var(children_random))^2/length(children_random)+(var(children_conv
))^2/length(children_conv))
> se2
[1] 0.602562
```

```
di2_90 <- 0.01 + c(-1, 1)*z_90*se2
di2_95 <- 0.01 + c(-1, 1)*z_95*se2
di2_99 <- 0.01 + c(-1, 1)*z_99*se2
```

```
data.frame(
  Уровень_доверия = c("90%", "95%", "99%"),
  Нижняя_граница = c(di2_90[1], di2_95[1], di2_99[1]),
  Верхняя_граница = c(di2_90[2], di2_95[2], di2_99[2])
)
```

Результат вывода данного кода:

	Уровень_доверия	Нижняя_граница	Верхняя_граница
1	90%	-0.9812145	1.001215
2	95%	-1.1710216	1.191022
3	99%	-1.5421998	1.562200

Стандартная ошибка разницы 0.603 является довольно большой величиной, это может указывать на то, что означает, что статистика с меньшей вероятностью будет близка к значению генеральной совокупности. Наблюдаемая разница средних двух выборок составила 0.01, очень малую величину, однако она не имеет практического значения. Так как все полученные интервалы включают ноль, это может указывать на то, что различия между группами не являются статистически значимыми. Полученные данные не позволяют сказать об отсутствии различий между данными выборки случайной и удобной.

3. Удобной выборки и квотной выборки (мужчины)

Разница средних удобной выборки и квотной выборки (мужчины): $2,14 - 1,9 = 0,24$

```
se3 <-
sqrt((var(children_conv))^2/length(children_conv)+(var(quota_men))^2/length(quota_men))
di3_90 <- 0.24 + c(-1, 1)*z_90*se3
di3_95 <- 0.24 + c(-1, 1)*z_95*se3
di3_99 <- 0.24 + c(-1, 1)*z_99*se3
data.frame(
  Уровень_доверия = c("90%", "95%", "99%"),
  Нижняя_граница = c(di3_90[1], di3_95[1], di3_99[1]),
  Верхняя_граница = c(di3_90[2], di3_95[2], di3_99[2])
)
```

Результат вывода данного кода:

	Уровень_доверия	Нижняя_граница	Верхняя_граница
1	90%	-0.3499903	0.8299903
2	95%	-0.4629672	0.9429672
3	99%	-0.6838997	1.1638997

На всех уровнях доверия (90%, 95%, 99%) интервалы включают ноль, различия не достигают статистической значимости ни на одном стандартном уровне. Хотя точечная оценка показывает небольшое превышение (0.24 ребенка) в удобной выборке, этот результат нестабилен. На полученную статистику может влиять небольшой размер выборок и наличие выбросов.

4. Квотных выборок (для дополнительного сравнения в качестве проверки гипотезы).

Разница средних значений по данным квотных выборок по мужчинам и по женщинам: $1,9 - 1,73 = 0,17$

```
se4 <-
sqrt((var(quota_women))^2/length(quota_women)+(var(quota_men))^2/length(
quota_men))
di4_90 <- 0.17 + c(-1, 1)*z_90*se4
di4_95 <- 0.17 + c(-1, 1)*z_95*se4
di4_99 <- 0.17 +c(-1, 1)*z_99*se4
data.frame(
  Уровень_доверия = c("90%", "95%", "99%"),
  Нижняя_граница = c(di4_90[1], di4_95[1], di4_99[1]),
  Верхняя_граница = c(di4_90[2], di4_95[2], di4_99[2])
)
```

Результат вывода данного кода:

	Уровень_доверия	Нижняя_граница	Верхняя_граница
1	90%	-0.3749867	0.7149867
2	95%	-0.4793459	0.8193459
3	99%	-0.6834260	1.0234260

Широкие интервалы указывают на: небольшие размеры выборок ($n=31$ и $n=33$), а также существенную вариативность в ответах. Все полученные интервалы включают ноль. Результаты не выявили статистически значимых гендерных различий в репродуктивных установках.

```
ci_data <- data.frame(
  Comparison = rep(c("Случайная vs Квотная (ж)", "Случайная vs Удобная",
    "Удобная vs Квотная (м)", "Квотная (м) vs Квотная
(ж)"), each = 3),
  Level = rep(c("90%", "95%", "99%"), 4),
  Lower = c(-0.545, -0.730, -1.091, -0.981, -1.171, -1.542, -0.350,
-0.463, -0.684, -0.375, -0.479, -0.683),
  Upper = c(1.385, 1.570, 1.931, 1.001, 1.191, 1.562, 0.830, 0.943,
1.164, 0.715, 0.819, 1.023),
  Point = c(0.42, 0.42, 0.42, 0.01, 0.01, 0.01, 0.24, 0.24, 0.24, 0.17,
0.17, 0.17))
```




```

)
library(ggplot2)

ggplot(ci_data, aes(x = Comparison, y = Point, color = Level)) +
  geom_point(position = position_dodge(width = 0.5), size = 3) +
  geom_errorbar(aes(ymin = Lower, ymax = Upper),
               width = 0.2, position = position_dodge(width = 0.5)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "red") +
  labs(title = "Доверительные интервалы для разницы средних",
       y = "Разница средних", x = "") +
  theme_minimal() +
  coord_flip()

```

Рисунок 6. Графики доверительных интервалов для разницы средних по уровням значимости 90%, 95%, 99%



Интерпретация: все интервалы пересекают нулевую линию (красная пунктирная), ширина интервалов увеличивается с повышением уровня доверия. Наибольшая неопределенность наблюдается при сравнении случайной выборки с другими.

Ни одно из сравнений не показало статистически значимых различий. Наибольшая разница (0.42 ребенка) наблюдается между случайной выборкой и квотной выборкой женщин, но даже она не значима. Гендерные различия минимальны (0.17 ребенка) и статистически не значимы. Результаты подтверждают общую тенденцию к малолетности во всех группах.

Сравнение желаемого количества детей у мужчин и женщин

```
quota_men <- c(2, 0, 3, 2, 1, 2, 2, 1, 1, 2, 1, 2, 2, 1, 1, 1, 2, 1, 3,
3, 4, 7, 2, 1, 1, 4, 1, 2, 1, 2, 1)
quota_women <- c(2, 1, 2, 2, 2, 1, 2, 2, 2, 2, 1, 2, 3, 0, 2, 2, 1, 2,
2, 3, 2, 1, 1, 1, 2, 2, 2, 0, 3, 1, 3, 2, 1)
```

Проверим гипотезу о том, что мужчины и женщины хотят иметь одинаковое количество детей в собственной семье (по результатам квотной выборки):

$$H_0: \mu_{\text{жен.}} = \mu_{\text{муж.}}$$

$$H_1: \mu_{\text{жен.}} \neq \mu_{\text{муж.}}$$

μ - среднее количество детей

Для двустороннего анализа используем тестовую статистику для разницы между двумя средними, когда дисперсии неизвестны и не равны, поскольку размер выборки составляет $n > 30$:

$$Z = \frac{x_1 - x_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} - \frac{\sigma_2^2}{n_2}}}$$

Рассчитаем Z score:

```
> z <- (mean(quota_men) -
mean(quota_women))/sqrt((var(quota_men))^2/length(quota_men)+(var(quota_
women))^2/length(quota_women))
> z
[1] 0.5311007
```

Рассчитаем p-value для двустороннего теста.

```
> p_value <- 2 * (1 - pnorm(abs(z)))
> p_value
[1] 0.595349
```

Создадим график для проверки гипотезы о гендерных различиях в желаемом количестве детей.

```
z_value <- 0.531
critical_values <- data.frame(
  level = c("90%", "95%", "99%"),
  z = c(qnorm(0.95), qnorm(0.975), qnorm(0.995)), # 1.645, 1.96, 2.576
  alpha = c(0.10, 0.05, 0.01)
)
```

```

x <- seq(-3.5, 3.5, length.out = 200)
norm_data <- data.frame(x = x, y = dnorm(x))

ggplot(norm_data, aes(x = x)) +
  # Основная линия распределения
  geom_line(aes(y = y), size = 1) +
  # Области отвержения для разных уровней
  geom_area(data = subset(norm_data, x >= critical_values$z[1]),
            aes(y = y), fill = "pink", alpha = 0.3) +
  geom_area(data = subset(norm_data, x <= -critical_values$z[1]),
            aes(y = y), fill = "pink", alpha = 0.3) +

  geom_area(data = subset(norm_data, x >= critical_values$z[2]),
            aes(y = y), fill = "red", alpha = 0.3) +
  geom_area(data = subset(norm_data, x <= -critical_values$z[2]),
            aes(y = y), fill = "red", alpha = 0.3) +

  geom_area(data = subset(norm_data, x >= critical_values$z[3]),
            aes(y = y), fill = "darkred", alpha = 0.3) +
  geom_area(data = subset(norm_data, x <= -critical_values$z[3]),
            aes(y = y), fill = "darkred", alpha = 0.3) +

  # Критические линии
  geom_vline(xintercept = critical_values$z, linetype = "dashed",
            color = c("pink", "red", "darkred")) +
  geom_vline(xintercept = -critical_values$z, linetype = "dashed",
            color = c("pink", "red", "darkred")) +

  # Наблюдаемое значение Z
  geom_vline(xintercept = z_value, color = "blue", size = 1.5) +

  # Подписи
  annotate("text", x = z_value, y = 0.2, label = paste("Z =",
    round(z_value, 2)),
    color = "blue", hjust = -0.2) +
  annotate("text", x = 2.7, y = 0.3, label = paste("p-value = 0.60"),
    color = "blue") +

  # Легенда для уровней значимости
  annotate("rect", xmin = 2.8, xmax = 3.2, ymin = 0.35, ymax = 0.45,
    fill = "pink", alpha = 0.3) +
  annotate("text", x = 3.3, y = 0.4, label = "α = 0.10", hjust = 0) +

  annotate("rect", xmin = 2.8, xmax = 3.2, ymin = 0.25, ymax = 0.35,
    fill = "red", alpha = 0.3) +
  annotate("text", x = 3.3, y = 0.3, label = "α = 0.05", hjust = 0) +

```


```

  annotate("rect", xmin = 2.8, xmax = 3.2, ymin = 0.15, ymax = 0.25,
    fill = "darkred", alpha = 0.3) +
  annotate("text", x = 3.3, y = 0.2, label = " $\alpha = 0.01$ ", hjust = 0) +

  labs(title = "Проверка гипотезы о гендерных различиях в желаемом
количестве детей",
    subtitle = "Двусторонний Z-тест с отображением областей отвержения
для разных уровней значимости",
    x = "Z-статистика",
    y = "Плотность вероятности") +
  theme_minimal() +
  theme(plot.title = element_text(size = 14, face = "bold"),
    plot.subtitle = element_text(size = 10))

```

Рисунок 7. График для проверки гипотезы о гендерных различиях в желаемом количестве детей



Цветные области: светло-розовый ($\alpha=0.10$): критические значения ± 1.645 , красный ($\alpha=0.05$): критические значения ± 1.96 , темно-красный ($\alpha=0.01$): критические значения ± 2.576 . Синяя вертикальная линия - наблюдаемое значение Z-статистики (0.53)

Из графика на рисунке можем сделать вывод, что Z-статистика (0.53) не попадает ни в одну из критических областей, p-value (0.60) значительно превышает все стандартные уровни значимости. Следовательно, нет оснований отвергать нулевую гипотезу об отсутствии различий. График наглядно показывает, что даже при самом мягком уровне

значимости (10%) мы не можем обнаружить статистически значимых различий между мужчинами и женщинами в желаемом количестве детей. Вывод: гипотеза H_0 о том, что средние значения желаемого количества детей у мужчин и женщин совпадает, не может быть отвергнута на всех стандартных уровнях значимости.

Задание 4: Разработка фальсифицированного исследования

Придумайте манипулятивное исследование, которое можно использовать для искажения данных.

- Опишите, как можно сфальсифицировать результаты с помощью:
 - Предвзятых методов выборки (например, convenience sample, self-selected sample и т.д.).
 - Завуалированных вопросов.
 - Ошибок выборки (selection bias, non-response bias).
- Объясните, как можно раскрыть искажения и как отличить качественное исследование от манипулятивного.

Создание исследования

Нами было придумано манипулятивное исследование на тему определения лжи в разговоре с людьми. Целью исследования было показать, что большинство людей умеют различать ложь в диалоге, а так же считают, что другие люди могут легко различить их ложь.

Ниже представлен список вопросов:

Тема: Как может проявляться ложь в разговоре?

1 блок:

1. Как вы считаете, избегание зрительного контакта может быть одним из признаков того, что человек лжет?
 - Да
 - Нет
2. Как вы считаете, продолжительные паузы в разговоре могут быть признаком того, что человек лжет?
 - Да
 - Нет
3. Как вы считаете, покраснение кончиков ушей или покраснение щек может быть признаком того, что человек лжет?
 - Да
 - Нет

2 блок:

4. Какие ещё признаки того, что человек лжет, вы можете назвать?
 - Открытый вопрос

5. Как вы думаете, чем отличается поведение ребенка от поведения взрослого во время лжи?
 - Открытый вопрос
6. Какие признаки (из вышеперечисленных или которые вы назвали) есть у вас в момент, когда вы лжете?
 - Открытый вопрос

3 блок:

7. Как вы думаете, вы можете понять, когда человек начинает говорить неправду?
 - Да
 - Нет
8. Как вы думаете, другие люди могут по вашей реакции догадаться, когда вы лжете?
 - Да
 - Нет

Фальсификация результатов

Для достижения цели исследования результаты были сфальсифицированы несколькими способами:

1. Предвзятые методы выборки

- convenience sample - выборка, которая включает в себя опрашиваемых, которые наиболее доступны в данный момент
- self-selected sample - выборка, которая включает в себя самостоятельный выбор того, кого опрашивать

Данные методы делают выборку нерепрезентативной, т.к. представляют людей со схожими признаками (доступность в конкретный момент времени может означать, что люди не учатся/не работают и т.д.) и позволяют заранее предугадать полученные результаты (самостоятельный выбор только тех людей, которые потенциально с большей вероятностью ответят на вопрос “да”). В нашем исследовании мы использовали оба метода и опрашивали своих знакомых, у которых имеем представление о характере и сфере деятельности. Опрошенные - наши знакомые студенты (convenience sample), честные люди, которые доверяют другим и которые чувствуют себя совестно, когда лгут (self-selected sample).

2. Завуалированные вопросы

- Фрейминг
Существует такое понятие как фрейминг, которое означает, что вопросы могут раскрываться с определенной стороны. Например, выжило 60% человек и умерло

40% человек означают одно и то же, но людьми воспринимается по-разному. Мнение и выбор людей может меняться в зависимости от формулировок (к данному заключению пришли в своих работах Даниэль Канеман и Амос Тверски).

- Неоднозначная формулировка вопросов
Вопрос можно понять по-разному
- Наводящие вопросы
Вопрос сформулирован таким образом, чтобы человек подсознательно ответил на него нужным для исследователя вариантом
- Психологический фактор
Вопросы выстроены в определенной логической последовательности, которая подводит опрашиваемого к нужному выводу

В нашем исследовании используются вышеперечисленные методы завуалированных вопросов:

- Фрейминг
Все вопросы кроме одного содержат слово “ложь”. Проходя опрос, человек сразу настраивается именно на обнаружении “лжи”. Он вспоминает только вещи, связанные с ложью (признаки, ситуации и т.д.). В данном случае происходит концентрация опрашиваемого на понятии лжи и ее обнаружении в разговоре с людьми, а не на понятии правды. Однако вопросы можно было задавать по другому: “какие признаки не говорят о том, что человек говорит неправду?” И в данном случае опрашиваемый сконцентрировался бы на неверном определении лжи и на том, что люди часто ошибаются, когда определяют ложь.
- Наводящие вопросы
Вопросы сформулированы со словосочетанием “может быть” (“избегание зрительного контакта может быть одним из признаков того, что человек лжет?”). Это подразумевает, что избегание зрительного контакта в определенных ситуациях будет признаком лжи, а в некоторых ситуациях может и не быть. Формулировка вопроса позволяет получить большее количество ответов “да” и настроить человека на обнаружение лжи.
- Психологический фактор:
Вопросы делятся на три блока: признаки лжи, размышления опрашиваемого, определение лжи.
 1. Первый блок направлен на то, чтобы показать, какие признаки лжи существуют и что люди умеют определять их визуально.
 2. Второй блок вопросов направлен на то, чтобы погрузить людей в тему и сподвигнуть их вспомнить ситуации, когда они сталкивались с ложью и когда лгали сами.

3. Третий блок - это непосредственно главная цель исследования. В ней опрашиваемые приходят к выводу, что на основе признаков лжи они могут определять ложь и другие люди могут определять моменты, в которых они могут лгать.

Благодаря данным вопросам вероятность того, что опрашиваемый ответит, что он может понять, когда другие говорят ложь и другие могут понять, когда он лжет, повышается.

3. Ошибки выборки

Существует несколько типов selection bias:

Sampling bias - характеристики участников не соответствуют характеристикам большинства людей, из-за чего выводы нельзя обобщить

Attrition bias - опрашиваемые покидают исследование и выборка перестает быть репрезентативной

Survivorship bias - ошибка выжившего (рассматриваются только успешные случаи)

Self-selection bias - в опросе участвуют люди с определенными характеристиками, которые сподвигли их на участие в опросе, из-за чего выводы сложно обобщить для всех людей (т.е. для тех, кто решил не участвовать в опросе)

Non-response bias - опрошенные не отвечают на опрос, из-за чего выборка перестает быть репрезентативной

В нашем исследовании из-за методов выборки наблюдаются такие ошибки как **Sampling bias** и **Self-selection bias**, т.к. мы опрашивали знакомых студентов, с которыми у нас хорошие отношения, из-за чего выводы правдивы для конкретной выборки, но для всего населения в целом нельзя сказать однозначно.

Результаты опроса:

 Новая форма (Ответы)

Ключевой блок вопросов: 3 блок. Предыдущие блоки подводят опрашиваемых к ответу “да” на вопросы ниже.


Рисунок 8. Статистика ответов на первый тестовый вопрос.



Рисунок 9. Статистика ответов на второй тестовый вопрос.

Как вы думаете, другие люди могут по вашей реакции догадаться, когда вы лжете?

20 ответов



- Большая часть опрошиваемых (55%) считает, что может понять, когда человек говорит неправду;
- большая часть опрошиваемых (85%) считает, что другие люди могут понять, когда они лгут.


Вывод: большинство опрошенных умеют различать ложь в диалоге, но ещё большее количество опрошенных считают, что другие люди могут различить их ложь.

Исследование на определение лжи, Тим Левин (Truth-default theory (TDT)), 1999.

В 1999 году Тим Левин опубликовал свое исследование на тему определения лжи, названное “теория истинного умолчания” [4]. В исследовании описывается эксперимент, в котором люди определяли по видеозаписям лжет человек или нет. В среднем люди верно определяли 56% лжецов из 44 видеозаписей. Позже были проведены дополнительные исследования, которые показали, что люди определяют лишь 54% лжецов, что немного больше, чем обычное “подбрасывание монеты”. Среди участников эксперимента были люди разных профессий: полицейские, судьи, психоаналитики, люди из ЦРУ и др..

Сравнение результатов исследований

Рисунок 10. Сравнение результатов исследований.



Сравнение:

- в нашем исследовании доля людей, которые считают, что могут верно определить ложь примерно совпадает с долей лжецов, которых верно определили в исследовании Т. Левина (55% и 56%)
- в нашем исследовании доля людей, которая считает, что другие люди определяют их ложь на 29 п.п. больше чем доля верно определенных лжецов в исследовании Т. Левина (85% и 56%)

Вывод:

Опрошенные нами люди сильно завышают возможность определения лжи другими людьми, что подтверждает утверждение о том, что результаты сфальсифицированы за счёт методов выборки, завуалированных вопросов и ошибок выборки.

Раскрытие искажений и определение качественного исследования

1. Раскрытие искажений

Для раскрытия искажений следует проводить дополнительные исследования с изменившимися условиями:

- проведение исследования в разных странах для выявления влияния культурных особенностей на выводы исследования
- смена методов формирования выборки опрашиваемых (например, опрашивать не только тех, кто хочет пройти опрос)
- опрос разных профессий, статуса и положения в обществе, расы, национальности и т.д.
- увеличение размера выборки

2. Качественное исследование

Качественное исследование должно заключать в себе несколько признаков:

- Репрезентативность выборки
- Значительный размер выборки (нахождения размера выборки в соответствии с стандартным отклонением)
- Указание методов создания выборки (прозрачность методов исследования)
- Исследование разных групп (по расе, национальности, профессии и т.д.)
- Отсутствие двусмысленной трактовки вопросов, наводящих вопросов, фрейминга
- Исследование возможных ошибок опроса (смещение выборки)
- Наличие критики исследования
- Публикация в достойном доверия научном журнале

Источники:

1. «Российский мониторинг экономического положения и здоровья населения НИУ ВШЭ (RLMS HSE)», проводимый Национальным исследовательским университетом "Высшая школа экономики" и ООО «Демоскоп» при участии Центра народонаселения Университета Северной Каролины в Чапел Хилле и Института социологии Федерального научно-исследовательского социологического центра РАН. (Сайты обследования RLMS HSE: <http://www.hse.ru/rlms> и <https://rlms-hse.cpc.unc.edu>)».
2. Спад экономики в 2022 году оказался меньше, чем в пандемию // РБК URL: <https://www.rbc.ru/economics/20/02/2023/63f3751b9a7947fbecbdf0c5> (дата обращения: 10.06.25).
3. С начала года продажи антидепрессантов выросли более чем в полтора раза // РБК URL: <https://www.rbc.ru/business/06/07/2022/62c468c29a79478ae0c63517?ysclid=mbw11uecc0294147982> (дата обращения: 10.06.25).
4. Levine, T. R., Park, H. S., & McCornack, S. A. (1999). Accuracy in detecting truths and lies: Documenting the “veracity effect.” *Communication Monographs*, 66(2), 125–144. <https://doi.org/10.1080/03637759909376468>.
Short link: [Тим Левин.pdf - Google Диск](#).