

Федеральное государственное автономное образовательное учреждение высшего
образования

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Санкт-Петербургская школа экономики и менеджмента

Прикладная статистика

Домашнее задание 3: Доверительные интервалы и проверка гипотез
(на основе данных RLMS-HSE и собственных опросов)

Направление 38.03.01 «Экономика»; 38.03.02 «Менеджмент»
Образовательная программа «Международный бакалавриат по бизнесу и
экономике»

Выполнили:

Алтышева Жанна БМББЭ2302
Бегитова Кристина БМББЭ2302
Емшанова Евгения БМББЭ2302
Ермакова Екатерина БМББЭ2302
Есина Виктория БМББЭ2302
Казакова Анна БМББЭ2302

Преподаватель:

Т. Л. Журавлева, Доцент НИУ ВШЭ в Санкт-Петербурге,
Санкт-Петербургская школа экономики и менеджмента,
Департамент экономики

Санкт-Петербург

2025

Оглавление

Задание 1. Разрыв в доходах между мужчинами и женщинами.....	3
Задание 2. Интернет среди пожилых.....	18
Задание 3. Семья и работа.....	26
Задание 4. До и после: здоровье и пандемия.....	41
Источники:.....	66

Задание 1. Разрыв в доходах между мужчинами и женщинами

1. **Загрузка и подготовка данных.** Перейдите на официальный сайт RLMS-HSE <https://www.hse.ru/rlms> и скачайте данные за интересующий вас год.

```
# Импорт библиотек
library("haven")
library(ggplot2)

# Чтение датасета
main_df = read_sav("/Users/timur/Desktop/2 задание R/r28i_os_74.sav")
# Создание датафрейма с интересующими метриками
df <- data.frame(
  "id" = main_df$idind,
  "sex" = main_df$х5,
  "region" = main_df$psu,
  "job" = main_df$хj4.1,
  "salary" = main_df$хj10
)
# Отфильтровывание датафрейма по интересующему региону
filtered_df <- subset(subset(df, region == 2), job == 10)
```

2. Выбор подмножества данных:

- Выберите один конкретный год (например, 2021).
- Выберите один город (например, Москва, Екатеринбург и т.д.) или работайте по всей стране.
- Выберите одну отрасль (например, образование, медицина, промышленность). Найдите переменную в данных RLMS-HSE, отвечающую за отрасль.
- Найдите переменную, отражающую зарплату.
- Сохраните нужные вам данные в R.

В данном задании мы провели анализ различий в заработных платах мужчин и женщин в сфере образования в городе Москва в 2019 году. Выборка состоит из 30 значений: 24 значения заработной платы женщин и 6 значений заработной платы мужчин. Небольшое количество значений заработной платы мужчин можно объяснить тем, что зачастую работники в сфере образования являются женщинами.

3. Построение доверительных интервалов.

- Постройте два отдельных доверительных интервала для средней зарплаты мужчин и женщин в выбранном вами году, городе и отрасли.
- Постройте доверительные интервалы для разных уровней значимости (например, 90%, 95%, 99%).
- Интерпретация. Объясните, что означают построенные интервалы в контексте социальной политики, рынка труда, равенства и т.д.

```
# Вводим функцию для нахождения доверительного интервала
# для выборки определенного пола с определенным уровнем значимости
confidence_interval <- function(input_df, input_sex, lvl) {
  # Отфильтровывание датафрейма по интересующему полу
  input_df = subset(input_df, sex == input_sex)
  # Нахождение среднего
  salary_mean = mean(input_df$salary)
  # Нахождение дисперсии
  salary_var = var(input_df$salary)
  # Нахождение стандартной ошибки
  SE = (salary_var / length(input_df$salary))**0.5
  # Нахождение критерия Стьюдента для данного уровня
  # значимости и размера выборки
  st_cr = qt(p= 1 - (1 - lvl) / 2, df=length(input_df$salary)-1)
  # Расчет доверительного интервала
  conf_int = c(
    salary_mean - st_cr * SE,
    salary_mean + st_cr * SE
  )
  # Возврат ответа
  return(c(input_sex, lvl, conf_int))
}
```

```
# Расчет доверительного интервала для интересующих уровней значимости
print("Пол  Уровень значимости  Доверительный интервал")
for (i in c(1, 2)) {
  for (j in c(0.9, 0.95, 0.99)) {
    ans = confidence_interval(filtered_df, i, j)
    print(ans)
  }
}
```


```
# Построение графика доверительных интервалов для мужчин
# Нижнии границы интервалов
lower_bounds <- c(35044.30, 31309.39, 21483.17)
# Верхние границы интервалов
```

```

upper_bounds <- c(62139.04, 65873.94, 75700.17)
# Подготовка данных в виде датафрейма
ci_data <- data.frame(
  Confidence_Level = c(0.90, 0.95, 0.99) * 100,
  Lower = lower_bounds,
  Upper = upper_bounds
)
# Построение графика
ggplot(ci_data, aes(x = Confidence_Level)) +
  geom_errorbar(aes(ymin = Lower, ymax = Upper), width = 0.3, color =
"steelblue", size = 1.2) +
  geom_point(aes(y = Lower), shape = 16, color = "red") +
  geom_point(aes(y = Upper), shape = 16, color = "red") +
  geom_text(aes(y = Upper, label = paste0("", round(Upper, 0))), vjust =
-0.5, size = 3.5) +
  geom_text(aes(y = Lower, label = paste0("", round(Lower, 0))), vjust =
1.5, size = 3.5) +
  scale_x_continuous(breaks = c(90, 95, 99), labels = c("90", "95",
"99")) +
  labs(
    title = "Доверительные интервалы средней зарплаты для мужчин",
    x = "Уровень доверия (%)",
    y = "Значения доверительных интервалов"
  ) +
  theme_minimal()

```

График 1. Доверительные интервалы средней заработной платы мужчин



Полученные доверительные интервалы для мужчин составили:


При 90% уровне доверия: от 35 044 до 62 139 рублей.

При 95% уровне доверия: от 31 309 до 65 874 рублей.

При 99% уровне доверия: от 21 483 до 75 700 рублей.

```
# Построение графика доверительных интервалов для женщин
# Нижнии границы интервалов
lower_bounds <- c(44622.05, 42462.51, 37966.27)
# Верхние графницы интервалов
upper_bounds <- c(65486.29, 67645.82, 72142.07)
# Подготовка данных в виде датафрейма
ci_data <- data.frame(
  Confidence_Level = c(0.90, 0.95, 0.99) * 100,
  Lower = lower_bounds,
  Upper = upper_bounds
)
# Построение графика
ggplot(ci_data, aes(x = Confidence_Level)) +
  geom_errorbar(aes(ymin = Lower, ymax = Upper), width = 0.3, color =
"steelblue", size = 1.2) +
  geom_point(aes(y = Lower), shape = 16, color = "red") +
  geom_point(aes(y = Upper), shape = 16, color = "red") +
  geom_text(aes(y = Upper, label = paste0("", round(Upper, 0))), vjust =
-0.5, size = 3.5) +
  geom_text(aes(y = Lower, label = paste0("", round(Lower, 0))), vjust =
1.5, size = 3.5) +
  scale_x_continuous(breaks = c(90, 95, 99), labels = c("90", "95",
"99")) +
  labs(
    title = "Доверительные интервалы средней зарплаты для женщин",
    x = "Уровень доверия (%)",
    y = "Значения доверительных интервалов"
  ) +
  theme_minimal()
```

График 2. Доверительные интервалы средней заработной платы женщин



Полученные доверительные интервалы для женщин составили:

При 90% уровне доверия: от 44 622 до 65 486 рублей.

При 95% уровне доверия: от 42 463 до 67 646 рублей.

При 99% уровне доверия: от 37 966 до 72 142 рублей.

Анализируя данные доверительные интервалы зарплат мужчин и женщин, проживающих в Москве в 2019 году и работающих в сфере образования, в первую очередь можно заметить, что доверительные интервалы у мужчин шире доверительных интервалов у женщин на всех уровнях значимости, при этом при уровне доверия 99% интервал у мужчин расширяется до 21 483-75 700 руб., что говорит о высокой вариации заработных плат, а также что оценка средней заработной платы не надежна в связи с малым размером выборки ($n=6$) и возможным наличии выбросов (к примеру, наличие мужчин, которые занимают высокооплачиваемые должности). У женщин же более узкий доверительный интервал, что значит, что оценка средней заработной платы женщин более надежна. Однако, в целом мы не можем сравнить по заработной плате представителей женского и мужского пола, так как интервалы у обоих выборок довольно широкие. Допустим, что выборка репрезентативная и отражает ситуацию на рынке труда, тогда можно заметить, что несмотря на то, что нижнее значение доверительных интервалов у мужчин меньше, чем у женщин, все равно при 99% уровне значимости верхняя граница доверительного интервала мужчин больше, чем у женщин.

Возможно, такое происходит из-за того, что, в целом, мужчины работающие в школах, чаще всего занимают либо технические должности (например, сторож), которые низкооплачиваемые, либо наоборот руководящие должности (например, директор школы) в связи с стереотипностью профессий, а женщины, в основном, педагогами и завучами, из-за чего их заработная плата не сильно варьируется.

В связи с тем, что мы не можем точно сравнить доверительные интервалы средней заработной платы двух полов, основываясь на отдельно построенных доверительных интервалах, правильнее будет построить доверительный интервал для разницы независимых выборок с разными дисперсиями, так как выборочные дисперсии у мужчин и женщин различаются.

```
# рассмотрим подгруппу женщины
female<-sum(filtered_df$sex==2) #количество женщин
female_average_salary<-mean(filtered_df[filtered_df$sex==2, 'salary'])
#средняя зп женщин
D1<-var(filtered_df[filtered_df$sex==2, 'salary']) #дисперсия выборки зп
женщин

# рассмотрим подгруппу мужчины
male<-sum(filtered_df$sex==1) #количество мужчин
male_average_salary<-mean(filtered_df[filtered_df$sex==1, 'salary'])
#средняя зп мужчин
D2<-var(filtered_df[filtered_df$sex==1, 'salary']) #дисперсия выборки зп
мужчин

# расчет доверительного интервала для разницы
share<-sqrt((D1/female)+(D2/male))
lower10 <- female_average_salary-male_average_salary-1.312527*share #
нижняя граница доверительного интервала для  $\alpha = 0.1$ 
upper10 <- female_average_salary-male_average_salary+1.312527*share #
верхняя граница доверительного интервала для  $\alpha = 0.1$ 
paste0("[", round(lower10, 4), ", ", round(upper10, 4), "]") #
Доверительный интервал для 90% уровня значимости

share<-sqrt((D1/female)+(D2/male))
lower5 <- female_average_salary-male_average_salary-1.701131*share #
нижняя граница доверительного интервала для  $\alpha = 0.05$ 
upper5 <- female_average_salary-male_average_salary+1.701131*share #
верхняя граница доверительного интервала для  $\alpha = 0.05$ 
paste0("[", round(lower5, 4), ", ", round(upper5, 4), "]") #
Доверительный интервал для 95% уровня значимости
```

```

share<-sqrt((D1/female)+(D2/male))
lower1 <- female_average_salary-male_average_salary-2.46714*share #
нижняя граница доверительного интервала для α = 0.01
upper1 <- female_average_salary-male_average_salary+2.46714*share #
верхняя граница доверительного интервала для α = 0.01
paste0("[", round(lower1, 4), ", ", round(upper1, 4), "]") #
Доверительный интервал для 99% уровня значимости


#расчет доверительного интервала
ci_data <- data.frame(
  Level = c("90%", "95%", "99%"),
  Lower = c(round(lower10, 4), round(lower5, 4), round(lower1, 4)),
  Upper = c(round(upper10, 4), round(upper5, 4), round(upper1, 4))
)

print(ci_data)
#расчет середин доверительных интервалов для уровней значимости
average<-c((lower10+upper10)/2, (lower5+upper5)/2, (lower1+upper1)/2)
#построение графиков доверительных интервалов
ggplot(ci_data, aes(x = Level, y = average)) +
  geom_point(size = 3) +
  geom_errorbar(aes(ymin = Lower, ymax = Upper), width = 0.1, color =
"blue2") +
  labs(title = "Доверительные интервалы (z-интервал) для среднего",
y = "Среднее значение", x = "Уровень доверия")

```

	Level	Lower	Upper
1	90%	-5441.049	18366.05
2	95%	-8965.371	21890.37
3	99%	-15912.448	28837.45

График 3. Доверительные интервалы



Вывод: поскольку ноль входит в доверительные интервалы на всех уровнях значимости, мы можем сделать вывод о том, что статистической разницы между их зарплатами нет, то есть нет значительной разницы между зарплатой женщин и зарплатой мужчин в Москве, работающих в сфере образования.

4. Проверка гипотезы о равенстве средних зарплат у мужчин и женщин. Проведите полный 5-этапный анализ, как обсуждалось на лекции:

1. Формулировка гипотез:

$$H_0 : \mu_{\text{муж}} = \mu_{\text{жен}} \quad \text{vs.} \quad H_1 : \mu_{\text{муж}} \neq \mu_{\text{жен}}$$

2. Выбор тестовой статистики и её распределения. Объясните какую статистику вы выбираете и посчитайте ее значение.
3. Критическая область или p-value: выберите уровень значимости α (например, 0,05), найдите критическое значение или рассчитайте p-value. Сделайте это для разных уровней значимости.
4. Статистическое решение: сравните значение тестовой статистики с критическим значением / p-value с α . Примите решение.
5. Интерпретация: объясните, что результат теста означает для реального мира. Что можно утверждать о различиях в зарплате?
6. Проведите точно такой же пятиэтапный анализ, когда альтернативная гипотеза $H_1 : \mu_{\text{муж}} > \mu_{\text{жен}}$

5- этапный анализ двустороннего теста

- 1.

$$H_0 : \mu_{\text{муж}} = \mu_{\text{жен}}$$

$$H_1 : \mu_{\text{муж}} \neq \mu_{\text{жен}}$$

2. Для одностороннего и двустороннего анализа используем тестовую статистику для разницы между двумя средними, когда дисперсии неизвестны и равны, поскольку размер выборки составляет $n = 30$ и мы сравниваем зарплаты мужчин и женщин из одной сферы за один и тот же период времени, поэтому предполагаем, что их дисперсии равны. Посчитаем тестовое значение по формуле и с помощью функций R.

$$T = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sqrt{s_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

```

# Вводим функцию для анализа Стьюдента
two_sample_test <- function(input_df, lvl) {
  # Расчет среднего и дисперсии для выборки мужчин и женщин
  salary_mean_1 = mean(input_df$salary[input_df$sex==1])
  salary_var_1 = var(input_df$salary[input_df$sex==1])
  salary_mean_2 = mean(input_df$salary[input_df$sex==2])
  salary_var_2 = var(input_df$salary[input_df$sex==2])
  # Расчет размера выборки
  n1 = length(input_df$salary[input_df$sex==1])
  n2 = length(input_df$salary[input_df$sex==2])
  # Расчет пулливированной дисперсии
  pulled_salary_var = ((n1 - 1) * salary_var_1 + (n2 - 1) * salary_var_2)
  / (n1 + n2 - 2)
  # Нахождение тестовой статистики
  test_stat = (salary_mean_1 - salary_mean_2) / (pulled_salary_var * (1 /
n1 + 1 / n2))**0.5
  # То же, что и в строках 46-56
  t = t.test(input_df$salary[input_df$sex==2],
input_df$salary[input_df$sex==1], var.equal = TRUE, conf.level = lvl)
  # Возврат ответа
  return(test_stat)
  return(t$statistic)
}

```

```

# Расчет тестовой статистики
two_sample_test(filtered_df, 0.95)

```

Расчетная тестовая статистика составила 0.5073364

3. Для двустороннего анализа берем уровень значимости 10%, 5% и 1% для двусторонней альтернативы, вычисляем уровень значимости.

```

# Расчет предельных значений для двустороннего анализа
print("Предельные значения для двустороннего анализа")
for (i in c(0.1, 0.05, 0.01)) {
  print(qt(p=i, df=length(filtered_df$salary)-2))
}

```

Критические значения для двустороннего анализа для следующих уровней значимости составили:

10% - 1,3125

5% - 1,701

1% - 2,467

Построим график распределения и обозначим на нём значение тестовой статистики и критические значения для разных уровней значимости.

```
# Визуализация

# Двусторонний анализ
# Создание переменных тестовой статистики и критических значений
t_stat <- two_sample_test(filtered_df, 0.95)
t_critical <- c(1.312527, 1.701131, 2.46714) # Для 10%, 5%, 1%

# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
               size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
            args = list(mean = 0, sd = 1),
            xlim = c(-3.5, -t_critical[1]), fill = "navyblue", alpha =
0.3) +
  geom_area(stat = "function", fun = dnorm,
            args = list(mean = 0, sd = 1),
            xlim = c(t_critical[1], 3.5), fill = "navyblue", alpha = 0.3)
+

  # Вертикальные линии для критических значений
  geom_vline(xintercept = c(-t_critical, t_critical),
             color = "navyblue", linetype = "dashed", size = 0.8) +

  # Линия t-статистики
  geom_vline(xintercept = t_stat, color = "red", size = 1) +


  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu_M = \mu_J$ ", size = 5) +
  geom_text(aes(x = t_stat, y = 0.1,
                label = paste0("t = ", round(t_stat, 3))),
            hjust = -0.1, vjust = -1, color = "red", size = 4) +

  # Подписи уровней значимости
  geom_text(aes(x = t_critical[1] + 0.1, y = 0.3, label = "10%"),
            color = "red", size = 3.5, hjust = 1) +
  geom_text(aes(x = t_critical[2] + 0.1, y = 0.3, label = "5%"),
            color = "red", size = 3.5, hjust = 1) +
  geom_text(aes(x = t_critical[3] + 0.1, y = 0.3, label = "1%"),
            color = "red", size = 3.5, hjust = 1) +

  # Оформление
```

```
labs(title = "Проверка гипотезы  $H_0: \mu_m = \mu_{ж}$ . Двусторонний анализ",
      subtitle = "Синие зоны - критические области, красная линия - наблюдаемое значение",
      x = "t-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
      axis.ticks.y = element_blank())
```

График 4. t-распределение для двустороннего анализа



4. Для всех уровней значимости критические значения больше тестовой статистики (0,507), поэтому мы не отвергаем нулевую гипотезу H_0 о том, что зарплаты мужчин и женщин в сфере образования в 2019 году в Москве равны, т.е. нет статистически значимых доказательств различий в средних зарплатах мужчин и женщин.
5. Интерпретация: в рамках данной выборки, состоящей из 30 значений, различия в зарплатах мужчин и женщин, работавших в сфере образования в 2019 году в Москве, статистически не подтверждаются. Основываясь на

полученных результатах выше о доверительных интервалах разницы независимых выборок, подтверждается, что если и есть различия в средней заработной плате, то они незначительные. Но также не стоит забывать, что объем выборки небольшой ($n = 30$), что снижает мощность теста и не дает возможность уверенно сказать, что зарплаты мужчин и женщин в действительности равны. Чтобы провести расширенный анализ можно увеличить объем выборки для повышения статистической мощности, а также можно разделить данные по категориям должностей или уровням квалификации для более точного анализа.

5-этапный анализ одностороннего теста

1.

$$H_0: \mu_{\text{муж}} = \mu_{\text{жен}}$$

$$H_1: \mu_{\text{муж}} > \mu_{\text{жен}}$$

2. Для одностороннего и двустороннего анализа используем тестовую статистику для разницы между двумя средними, когда дисперсии неизвестны и равны, поскольку размер выборки составляет $n = 30$ и мы сравниваем зарплаты мужчин и женщин из одной сферы за один и тот же период времени, поэтому предполагаем, что их дисперсии равны. Посчитаем тестовое значение по формуле и с помощью функций R.

$$T = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sqrt{s_p^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$$

```
# Вводим функцию для анализа Стьюдента
two_sample_test <- function(input_df, lvl) {
  # Расчет среднего и дисперсии для выборки мужчин и женщин
  salary_mean_1 = mean(input_df$salary[input_df$sex==1])
  salary_var_1 = var(input_df$salary[input_df$sex==1])
  salary_mean_2 = mean(input_df$salary[input_df$sex==2])
  salary_var_2 = var(input_df$salary[input_df$sex==2])
  # Расчет размера выборки
  n1 = length(input_df$salary[input_df$sex==1])
  n2 = length(input_df$salary[input_df$sex==2])
  # Расчет пуллированной дисперсии
```

```

    pulled_salary_var = ((n1 - 1) * salary_var_1 + (n2 - 1) * salary_var_2)
    / (n1 + n2 - 2)
    # Нахождение тестовой статистики
    test_stat = (salary_mean_1 - salary_mean_2) / (pulled_salary_var * (1 /
n1 + 1 / n2))**0.5
    # То же, что и в строках 46-56
    t = t.test(input_df$salary[input_df$sex==2],
input_df$salary[input_df$sex==1], var.equal = TRUE, conf.level = lvl)
    # Возврат ответа
    return(test_stat)
    return(t$statistic)
}

```

```

# Расчет тестовой статистики
two_sample_test(filtered_df, 0.95)

```

Расчетная тестовая статистика составила 0.5073364

3. Для двустороннего анализа берем уровень значимости 10%, 5% и 1% для односторонней альтернативы, вычисляем уровень значимости.

```

# Расчет предельных значений для одностороннего анализа
print("Предельные значения для одностороннего анализа")
for (i in c(0.05, 0.025, 0.005)) {
    print(qt(p=i, df=length(filtered_df$salary)-2))
}

```

Критические значения для одностороннего анализа для следующих уровней значимости составили:

10% - 1,701

5% - 2,048

1% - 2,763

Построим график распределения и обозначим на нём значение тестовой статистики и критические значения для разных уровней значимости.

```

# Односторонний анализ
# Создание переменных тестовой статистики и критических значений
t_stat <- two_sample_test(filtered_df, 0.95)

```

```

t_critical <- c(1.701131, 2.048407, 2.763262) # Для 10%, 5%, 1%

# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
               size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
            args = list(mean = 0, sd = 1),
            xlim = c(t_critical[1], 3.5), fill = "navyblue", alpha = 0.3)
+

  # Вертикальные линии для критических значений
  geom_vline(xintercept = c(t_critical),
             color = "navyblue", linetype = "dashed", size = 0.8) +

  # Линия t-статистики
  geom_vline(xintercept = t_stat, color = "red", size = 1) +


  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu_m = \mu_{ж}$ ", size = 5) +
  geom_text(aes(x = t_stat, y = 0.1,
               label = paste0("t = ", round(t_stat, 3))),
           hjust = -0.1, vjust = -1, color = "red", size = 4) +

  # Подписи уровней значимости
  geom_text(aes(x = t_critical[1] + 0.1, y = 0.3, label = "10%"),
           color = "red", size = 3.5, hjust = 1) +
  geom_text(aes(x = t_critical[2] + 0.1, y = 0.3, label = "5%"),
           color = "red", size = 3.5, hjust = 1) +
  geom_text(aes(x = t_critical[3] + 0.1, y = 0.3, label = "1%"),
           color = "red", size = 3.5, hjust = 1) +

  # Оформление
  labs(title = "Проверка гипотезы H0:  $\mu_m = \mu_{ж}$ . Односторонний анализ",
       subtitle = "Синие зоны - критические области, красная линия -
наблюдаемое значение",
       x = "t-статистика") +
  theme_minimal(base_size = 14) +
  theme(axis.text.y = element_blank(),
        axis.ticks.y = element_blank())

```

График 5. t-распределение для одностороннего анализа



4. Для всех уровней значимости критические значения больше тестовой статистики (0,507), поэтому мы не отвергаем нулевую гипотезу H_0 о том, что зарплаты мужчин равны зарплатам женщин в сфере образования в 2019 году в Москве.
5. Интерпретация: при проверке правосторонней гипотезы, мы получили, что нет доказательств того, что мужчины в сфере образования в Москве в среднем получают заработную плату больше чем женщины. Однако мы также не можем утверждать, что зарплаты мужчин и женщин в действительности были равны. Как было сказано ранее, ограничением анализа выступает небольшой объем выборки ($n = 30$), что снижает мощность теста.

Задание 2. Интернет среди пожилых

Пошаговая инструкция

1. **Сбор собственных данных.** Проведите мини-опрос среди людей старше 60 лет (например, ваших родственников, знакомых, соседей, в соцсетях и т.д.). Используйте простую Яндекс-форму или бумажный опросник. Запишите их возраст, пол и ответ на главный вопрос: «*Пользуетесь ли вы интернетом?*» (да/нет)

Нами был проведен мини-опрос среди людей старше 60 лет, который включал в себя три вопроса:

1. Ваш пол? (М/Ж)
2. Ваш возраст?
3. Пользуетесь ли Вы Интернетом? (Да/Нет)

В опросе приняло участие 88 человек, данные опроса представлены в виде векторов «sex», «age», «question»:

```
#выборка возраста респондентов пожилых от 60 лет, тип данных -
количественные дискретные
age <- c(64, 62, 67, 60, 65, 63, 71, 61, 63, 60, 66, 64, 62, 68, 60, 65,
63, 75, 61, 64, 62, 70, 60, 63, 65, 61, 72, 64, 62, 60, 69, 63, 65, 61,
64, 78, 62, 60, 63, 65, 61, 74, 64, 62, 60, 66, 63, 65, 61, 64, 80, 62,
60, 63, 65, 61, 76, 64, 62, 60, 63, 65, 61, 64, 73, 62, 60, 63, 65, 61,
64, 77, 62, 60, 63, 65, 61, 64, 79, 62, 60, 63, 65, 61, 64, 62, 60, 63)

#категориальные переменные, пол респондентов, где 1 - мужской, 0 -
женский
sex <- c(0, 1, 0, 1, 0, 0, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1,
0, 0, 0, 1, 0, 1, 0, 0, 0, 0, 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1,
0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, 0,
0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0)

#категориальные переменные, ответ на вопрос "Пользуетесь ли вы
Интернетом?", где 1 - "да", 0 - "нет"
question <- c(1, 1, 0, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1,
0, 1, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1,
1, 0, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1,
1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 1, 0, 1, 1, 0, 1, 1, 1, 1, 1)
```

2. Определение минимального объёма выборки:

Проведем анализ мощности (power analysis) для необходимого количества респондентов, используя функцию `power.drop.test()` в R.

Мы взяли данные из исследования, опубликованного агентством “Вебер”. Согласно исследованию, 91% россиян в возрасте 55-64 лет ежедневно пользуются интернетом, старше 65 тоже немало – 87 %. Опрос, опубликованный в марте 2025 года фондом “Общественное мнение”, демонстрирует, что примерно 51% пожилых старше 60 лет

пользуются Интернетом. Так как разница между результатами двух исследований достаточно большая, мы возьмем среднее значение, тогда альтернативная доля составляет 0,76.

```
power.prop.test(p1 = 0.76, p2 = 0.5, power = 0.9, sig.level = 0.05)
```

При альтернативной доле $p1 = 0.76$, нулевой гипотезе $p0 = 0.5$, мощности теста 90% и уровне значимости 5%, минимальный размер выборки составляет 77 человек. Следовательно, если мы берем выборку ≥ 77 человек, с вероятностью 0.9 тест правильно отвергнет ложную нулевую гипотезу.

3. Перенесите данные в R. Сделайте анализ средних всех трех собранных переменных.

При помощи следующих формул в R рассчитаем средние по трем переменным:

```
> mean(age)
[1] 64.29545
> mean(sex)
[1] 0.2666667
> mean(question)
[1] 0.8295455
```

Средний возраст респондентов выборки - 64,3 года.

Поскольку переменная «sex» закодирована как 0 (женский пол) и 1 (мужской), среднее значение интерпретируется как доля мужчин в выборке. Следовательно, мы имеем 27% респондентов мужчин и 73% женщин. Вывод: в нашей выборке преобладают женщины 60+.

Аналогично, переменная «question» закодирована как 0 (респондент не пользуется Интернетом) и 1 (пользуется), среднее значение интерпретируется как доля респондентов, пользующихся Интернетом. Следовательно, 83% респондентов пользуются Интернетом, что составляет большинство.

```
> median(age)
[1] 63
```

Медиана вектора возраста составляет 63. Это означает, что 50% респондентов младше 63 лет, а остальные 50% - больше 63 лет.

4. Построение доверительного интервала для доли.

- Рассчитайте долю пользователей интернета в вашей выборке ($\hat{p}$). :

$$p = \frac{73}{88} = 0,83$$

В данном случае $p = 0,83$ является средним значением «question».

Так как объем выборки больше 30, допустимо использовать стандартные нормальные значения в качестве аппроксимации. Это связано с тем, что t-распределение приближается к стандартному нормальному распределению по мере приближения степеней свободы к бесконечности.

- Постройте доверительный интервал для этой доли при различных уровнях значимости (90%, 95%, 99%).

С помощью функций R найдем z-значения при различных уровнях значимости (90%, 95%, 99%).

```
z_90 <- qnorm(0.95)
z_95 <- qnorm(0.975)
z_99 <- qnorm(0.995)
```

Рассчитаем стандартную ошибку по формуле:

```
se <- sqrt(p*(1-p)/88)
```

Рассчитаем доверительные интервалы по формулам при различных уровнях значимости. При помощи data.frame() наглядно выведем получившиеся доверительные интервалы.

```
z_values <- c(z_90, z_95, z_99)
conf_levels <- c("90%", "95%", "99%")
intervals <- sapply(z_values, function(z) p + c(-1, 1) * z * se)

data.frame(
  "Уровень доверия" = conf_levels,
  "Нижняя граница" = round(intervals[1, ], 3),
  "Верхняя граница" = round(intervals[2, ], 3)
)
```

Результат вывода кода:


	Уровень. доверия	Нижняя. граница	Верхняя. граница
1	90%	0.764	0.895
2	95%	0.751	0.908
3	99%	0.726	0.933

```

# Визуализация
# Создаем dataframe с результатами
results <- data.frame(
  "Уровень_доверия" = factor(conf_levels, levels = conf_levels),
  "Нижняя_граница" = intervals[1, ],
  "Верхняя_граница" = intervals[2, ],
  "Точка" = p
)
# Строим график
library(ggplot2)
ggplot(results, aes(x = Уровень_доверия, y = Точка)) +
  geom_point(size = 4, color = "dodgerblue") +
  geom_errorbar(aes(ymin = Нижняя_граница, ymax = Верхняя_граница),
    width = 0.1, size = 1, color = "firebrick") +
  geom_hline(yintercept = p, linetype = "dashed", color = "gray50") +
  labs(title = "Доверительные интервалы для доли
интернет-пользователей\нсреди пожилых респондентов",
    x = "Уровень доверия",
    y = "Доля пользователей",
    caption = paste0("Объем выборки: n = ", length(question))) +
  scale_y_continuous(limits = c(max(0, p - 0.2), min(1, p + 0.2)),
    breaks = seq(0, 1, 0.1)) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold"),
    panel.grid.minor = element_blank(),
    plot.caption = element_text(hjust = 0, color = "gray30")
  )

```

График 6. Доверительные интервалы



- Интерпретируйте: что говорит интервал? Насколько уверенно можно утверждать, что большинство/меньшинство пожилых людей пользуются интернетом?

Во всех полученных доверительных интервалах нижняя граница $> 50\%$, это значит, что с вероятностью, соответствующей уровню доверия (90%, 95%, 99%), истинная доля пожилых людей, пользующихся интернетом в генеральной совокупности, превышает 50%. Следовательно, можно уверенно утверждать, что большинство пожилых людей пользуются интернетом.

5. Проверка гипотезы. Проверьте гипотезу о том, что менее половины пожилых людей пользуются интернетом:

1. Формулировка гипотезы:

$$H_0 : \pi = 0,5 \quad \text{vs.} \quad H_1 : \pi < 0,5$$

2. Выбор и расчет тестовой статистики.

Тест - односторонний z-тест для доли:

$$Z = \frac{\hat{p} - \pi_0}{\sqrt{\frac{\pi_0(1-\pi_0)}{n}}}$$

По формуле z-статистики рассчитаем:

```
p0 = 0.5
z_ <- sqrt(p0*(1-p0)/n)
z <- (p - p0)/z_
```

$$z = 6.18$$

Принятие решения: если тестовая статистика попадает в критическую область, отвергаем H_0 . В противном случае H_0 не отвергается (недостаточно оснований для отклонения).

3. Критическая область или p-value: выберите $\alpha = 0,05$ и/или $\alpha = 0,01$, найдите критическое значение или рассчитайте p-value.

Возьмем $\alpha = 0.05$. Рассчитаем p-value, вероятность получения наблюдаемого значения тестовой статистики или более экстремального значения, при условии, что гипотеза H_0 верна.

```
a <- 0.05
p_value <- pnorm(6.18)
```

Результат: p-value ≈ 1 .

```
# Визуализация
library(ggplot2)
# Параметры теста
z_observed <- 6.05
z_crit_05 <- qnorm(0.05)
z_crit_01 <- qnorm(0.01)

# Создаем график
ggplot(data.frame(x = c(-4, 7)), aes(x)) +
  # Основная кривая нормального распределения
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
               size = 1, color = "black") +

  # Закрашиваем критическую область для  $\alpha=0.05$ 
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
               xlim = c(-4, z_crit_05),
               geom = "area", fill = "red", alpha = 0.3) +

  # Закрашиваем критическую область для  $\alpha=0.01$ 
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
               xlim = c(-4, z_crit_01),
               geom = "area", fill = "blue", alpha = 0.2) +

  # Линии критических значений
  geom_vline(xintercept = z_crit_05, color = "red", linetype = "dashed",
             size = 1) +
  geom_vline(xintercept = z_crit_01, color = "blue", linetype = "dashed",
             size = 1) +


  # Наблюдаемое значение Z
  geom_vline(xintercept = z_observed, color = "darkgreen", size = 1.5) +

  # Подписи
  annotate("text", x = z_crit_05, y = 0.1,
           label = "5% = -1.645",
           color = "red", hjust = 1.1) +
  annotate("text", x = z_crit_01, y = 0.15,
           label = "1 % = -2.326",
           color = "blue", hjust = 1.1) +
  annotate("text", x = z_observed, y = 0.3,
           label = paste0("Z = ", round(z_observed, 2)),
           color = "darkgreen", hjust = -0.1) +
```

```
# Легенда и заголовки
labs(title = "Проверка гипотезы:  $H_0: p=0.5$  vs  $H_1: p<0.5$ ",
      subtitle = "Критические области для разных уровней значимости",
      x = "Z-статистика",
      y = "Плотность вероятности") +

# Оформление
theme_minimal(base_size = 12) +
theme(plot.title = element_text(hjust = 0.5, face = "bold"),
      plot.subtitle = element_text(hjust = 0.5))
```

График 7. Проверка гипотезы



4. Статистическое решение: делаем вывод о том, можно ли отвергнуть гипотезу о том, что половина пожилых пользуется интернетом.

Интерпретация результата: $p\text{-value} \approx 1$ означает, что вероятность получить $z = 6.18$ при истинности H_0 мала.

Вывод: гипотеза H_0 отвергается на любом уровне значимости ($\alpha=0.05$ или $\alpha=0.01$). Можно отвергнуть гипотезу о том, что половина пожилых пользуется Интернетом.

5. Интерпретация: объясните, какие социальные выводы можно сделать. Какие факторы могут влиять? Стоит ли предпринимать меры для повышения цифровой грамотности?

Можно также сделать вывод, что, вопреки распространенному мнению, что малое количество пожилых пользуется Интернетом, с каждым годом уровень цифровой грамотности среди пожилого населения России повышается. Можно выделить факторы, которые влияют на увеличение числа лиц старше 60 лет, пользующихся Интернетом:

1. Помощь родственников и волонтеров в обучении пожилых пользованию Интернетом;
2. Наличие курсов цифровой грамотности (например, «Азбука интернета» в России);
3. К мотивации пожилых пользоваться Интернетом относится общение (соцсети, Zoom, Skype), онлайн-покупки, доступ к госуслугам, различные статьи и познавательные видеоролики, новости СМИ;
4. Желание пожилых быть в курсе киберпреступности и способах обезопасить себя, поддержка мобильных операторов и банков в вопросе кибербезопасности пожилых.

Задание 3. Семья и работа

1. **Загрузка и подготовка данных.** Загрузите RLMS-HSE с сайта <https://www.hse.ru/rlms>. Выберите один конкретный год (отличающийся от выбранного в задании 1).

```
library(haven)

path = file.path("C:/", "Users/Виктория/Downloads",
"данные2020_индивиды.sav")
dataset = read_sav(path)

# Создаем новый data.frame только с нужными переменными
selected_data <- data.frame(
  indiv = dataset$idind,      # уникальный номер индивида
  age = dataset$y_age,       # возраст
  sex = dataset$yh5,         # пол
  fam = dataset$yj322,       # семейное положение
  job = dataset$yj1          # занятость
)
# Оставляем индивидов от 25 до 45 лет и убираем NA из переменной age
filtered_data <- subset(selected_data, age >= 25 & age <= 45 &
!is.na(age))
```

2. Фильтрация данных:

- Возраст: выберите только людей от 25 до 45 лет.
- Переменная занятости: выберите переменную, отражающую, работает ли человек (например, по статусу занятости).
- Переменная семейного положения: выделите две группы:
 - Женатые/замужние (официально зарегистрированный брак);
 - Неженатые/незамужние (включая вдовых, разведённых, никогда не состоявших в браке).

Для выполнения задания были загружены данные RLMS-HSE за 2020 год (29 волна). Для дальнейшего анализа были выбраны 4 переменные, отражающие пол, возраст, семейное положение и статус занятости:

- 1) yh5 Пол респондента
- 2) y_age Возраст респондента
- 3) yj322 Состоите ли Вы в зарегистрированном браке?
- 4) yj1 Ваше основное занятие в настоящее время?

Для переменной, определяющей, является ли респондент женат/за мужем, взяты ответы 2,3,6 («Состоите в первом зарегистрированном браке», «Состоите в повторном зарегистрированном браке», «Зарегистрированы, но вместе не живут»). Для тех, кто не женат/не замужем – ответы 1,4,5 («Никогда в браке не состоял(а)», «Разведены», «Вдовец/вдова»).

Для определения работающих людей, выбраны люди, ответившие 1 («Вы сейчас работаете»).

Далее данные были отфильтрованы по возрасту: взяты респонденты от 25 до 45 лет.

3. Расчёт долей:

- Рассчитайте долю трудоустроенных среди женатых/замужних $\hat{p}_1$;
- Рассчитайте долю трудоустроенных среди неженатых/незамужних $\hat{p}_2$.

```
#Расчет долей
# Расчет количества людей в браке (fam = 2, 3 или 6)
married <- filtered_data[filtered_data$fam %in% c(2, 3, 6), ]

# Подсчет общего числа людей в браке
total_married <- nrow(married)

# Подсчет числа трудоустроенных людей в браке (job = 1)
employed_married <- sum(married$job == 1)

# Расчет доли трудоустроенных среди людей в браке (p1)
p1 <- employed_married / total_married

#Расчет количества людей не в браке (fam = 1, 4 или 5)
not_married <- filtered_data[filtered_data$fam %in% c(1, 4, 5), ]
total_not_married <- nrow(not_married)

#Расчет числа трудоустроенных людей не в браке
employed_not_married <- sum(not_married$job == 1)

# Расчет доли трудоустроенных среди людей не в браке (p1)
p2 <- employed_not_married / total_not_married
```

Доля трудоустроенных среди женатых/замужних составляет $p_1 = 0,7680707$.

Доля трудоустроенных среди неженатых/незамужних составляет $p_2 = 0,7406015$.

4. Построение доверительного интервала для разности долей:

- Постройте доверительный интервал для разности долей трудоустроенных между женатыми/замужними и нет для уровней значимости 90%, 95% и 99%.
- Интерпретируйте результат: каков возможный разрыв между группами?

```
#Построение доверительных интервалов для разности долей
```

```
n1 <- total_married #размер выборки людей в браке
n2 <- total_not_married #размер выборки людей не в браке
ESE <- sqrt((p1*(1-p1))/n1 + (p2*(1-p2))/n2) # стандартная ошибка
разности долей
lower10 <- (p1-p2)- 1.64 * ESE # нижняя граница доверительного интервала
для  $\alpha = 0.1$ 
upper10 <- (p1-p2) + 1.64 * ESE # верхняя граница доверительного интервала
для  $\alpha = 0.1$ 
paste0("[", round(lower10, 4), ", ", round(upper10, 4), "]") #
Доверительный интервал для 90% уровня значимости
```

```
lower5 <- (p1-p2)- 1.96 * ESE # нижняя граница доверительного интервала
для  $\alpha = 0.05$ 
upper5 <- (p1-p2) + 1.96 * ESE # верхняя граница доверительного интервала
для  $\alpha = 0.05$ 
paste0("[", round(lower5, 4), ", ", round(upper5, 4), "]") #
Доверительный интервал для 95% уровня значимости
```

```
lower1 <- (p1-p2)- 2.5758 * ESE # нижняя граница доверительного интервала
для  $\alpha = 0.01$ 
upper1 <- (p1-p2) + 2.5758 * ESE # верхняя граница доверительного
интервала для  $\alpha = 0.01$ 
paste0("[", round(lower1, 4), ", ", round(upper1, 4), "]") #
Доверительный интервал для 99% уровня значимости
```

```
# Визуализация доверительных интервалов
```


```
levels <- c("90%", "95%", "99%")
estimates <- rep(p1 - p2, 3)
lowers <- c(lower10, lower5, lower1)
uppers <- c(upper10, upper5, upper1)

plot(1:3, estimates, pch = 19, col = "black",
     xlim = c(0.5, 3.5), ylim = range(c(lowers, uppers)),
     xaxt = "n", xlab = "Уровень значимости", ylab = "Разность долей (p1
- p2)",
     main = "Доверительные интервалы разности долей")
axis(1, at = 1:3, labels = levels)
```

```
# Добавляем доверительные интервалы
arrows(1:3, lowers, 1:3, uppers,
      angle = 90, code = 3, length = 0.1, col = "darkred", lwd = 2)

# Добавляем нулевую линию
abline(h = 0, lty = 2, col = "gray50")
```

График 8. Доверительные интервалы для разности долей трудоустроенных между женатыми/замужними и нет



Полученные доверительные интервалы составили:

При 90% уровне доверия: [0.0022, 0.0527]

При 95% уровне доверия: [-0.0027, 0.0576]

При 99% уровне доверия: [-0.0122, 0.0671]

На уровне 90% значимости доверительный интервал не включает ноль, однако на уровне 95% и 99% значимости доверительные интервалы включают его, что говорит о статистически не значимом различии между показателями, т.е. данные не позволяют уверенно утверждать, что существует различие между работающими женатыми/замужними и работающими не женатыми/не замужними.

5. Проверка гипотезы о равенстве долей. Выполните анализ по всем 5 этапам:

1. Формулировка гипотез:

$$H_0 : \pi_{\text{в браке}} = \pi_{\text{не в браке}} \quad \text{vs.} \quad H_1 : \pi_{\text{в браке}} \neq \pi_{\text{не в браке}}$$

2. Выбор и расчет тестовой статистики:

3. Критическая область или p-value: выберите уровни значимости $\alpha = 0,10, 0,05, 0,01$.

4. Примите решение о принятии/отклонении нулевой гипотезы.

5. Интерпретация: сделайте вывод, влияет ли семейный статус на занятость. Что это может означать с социальной точки зрения?

1. Формулировка гипотез:

π_1 - доля трудоустроенных в браке

π_2 - доля трудоустроенных не в браке

$$H_0 : \pi_1 = \pi_2$$

$$H_1 : \pi_1 \neq \pi_2$$

2. Расчет Z-статистики для разницы между двумя долями генеральной совокупностей:

Так как мы проверяем гипотезу о равенстве, мы можем заключить, что $\pi_1 - \pi_2 = 0$.

Рассчитаем совокупную долю p и Z-статистику:

```
# №5 Проверка гипотезы о равенстве долей
p<-(employed_married+employed_not_married)/(total_married+total_not_married)
Z<- ((p1-p2)-0)/sqrt((p*(1-p)*(1/n1+1/n2)))

>Z
[1]1.795443
```

3. Мы проверяем гипотезу о равенстве долей, следовательно, используем двусторонние альтернативы при проверке гипотез:

```
Z_critical<-c(
  "10%" = qnorm(1 - 0.10/2),
  "5%" = qnorm(1 - 0.05/2),
  "1%" = qnorm(1 - 0.01/2)
```

```
)

results<-data.frame(
  Уровень = names(Z_critical),
  Z_критическое = Z_critical,
  Z_статистика=Z,
  Отклоняем_H0 = abs(Z)>Z_critical
)
```

```
> print(results)
      Уровень Z_критическое Z_статистика Отклоняем_H0
10%      10%      1.644854      1.795443         TRUE
5%       5%      1.959964      1.795443         FALSE
1%       1%      2.575829      1.795443         FALSE
>
```

$Z=1,795 > Z_{кр}=1,64$ при уровне значимости = 10%

$Z=1,795 < Z_{кр}=1,96$ при уровне значимости = 5%

$Z=1,795 < Z_{кр}=2,57$ при уровне значимости = 1%

4. Решение: при уровне значимости 10% мы отвергаем гипотезу о равенстве долей; при уровнях значимости 5% и 1% мы не можем отвергнуть гипотезу о равенстве долей.

```
#Визуализация
library(ggplot2)
#параметры текста

Z_critical<-c(1.645, 1.96, 2.576)
#создаем график
ggplot(data.frame(x=c(-3.5, 3.5)), aes(x)) +
  #Основное распределение
  stat_function(fun=dnorm, args=list(mean=0, sd=1),
               size=1.2, color="gray40")+
  #критические области закрашены красным
  geom_area(stat="function", fun=dnorm,
            args=list(mean=0, sd=1),
            xlim=c(Z_critical[1], 3.5), fill="red",
            alpha=0.3
            )+
  geom_area(stat="function", fun=dnorm,
            args=list(mean=0, sd=1),
            xlim=c(-3.5, -Z_critical[1]), fill="red",
            alpha=0.3
            )+
```

```

#вертикальные линии для критических значений
geom_vline(xintercept=c(-Z_critical, Z_critical),
           color="red", linetype="dashed", size=0.8)+

#линия Z-статистики
geom_vline(xintercept=Z, color="blue", size=1) +


#подписи
annotate("text", x=0, y=0.2, label="π1= π2", size=5)+
geom_text(aes(x=Z, y=0.1, label =paste0("Z = ", round(Z, 3))),
          hjust = -0.1, vjust=-1, color ="blue", size =4)+

#Подписи уровней значимости
geom_text(aes(x=Z_critical[1]+0.1, y = 0.3, label="10%"),
          color="red", size=3.5, hjust=1)+
geom_text(aes(x=Z_critical[2]+0.1, y = 0.3, label="5%"),
          color="red", size=3.5, hjust=1)+
geom_text(aes(x=Z_critical[3]+0.1, y = 0.3, label="1%"),
          color="red", size=3.5, hjust=1)+

#оформление
labs(title = "Проверка гипотезы π1=π2",
     subtitle ="Красные зоны - критические области, синяя линия -
наблюдаемое значение",
     x="Z-статистика"
    )+
theme_minimal(base_size = 14)+
theme(axis.text.y = element_blank(),
      axis.ticks = element_blank())

```

График 9. Проверка гипотезы о равенстве долей



5. Семейный статус не оказывает значительного влияния на занятость. С социальной точки зрения это может означать, что брак не мешает кардинально человеку найти работу.
6. **Сравнение по полу.** Повторите весь анализ отдельно для мужчин и для женщин:
 - Разделите выборку на мужчин и женщин.
 - Для каждой подгруппы (мужчины, женщины) повторите всю работу по п.5, т.е. проверьте гипотезу о равенстве долей трудоустроенных между женатыми и неженатыми мужчинами, замужними и незамужними женщинами.
 - Сравните результаты: различаются ли эффекты для мужчин и женщин?
 - Обсудите возможные причины различий: экономические, культурные, гендерные роли, ожидания со стороны работодателей и семьи.

```
# Разделим выборку на мужчин и женщин

# Количество замужних женщин
female_married<-sum(married$sex == 2) # значение женского пола = 2
# Количество незамужних женщин
female_not_married<-sum(not_married$sex == 2)
# Количество женатых мужчин
male_married<-sum(married$sex == 1) # значение мужского пола = 1
# Количество неженатых мужчин
male_not_married<-sum(not_married$sex == 1)

#замужние трудоустроенные женщины
```

```

female_employed_married<-sum(married$job == 1&married$sex == 2)
#незамужние трудоустроенные женщины
female_employed_not_married<-sum(not_married$job == 1&not_married$sex ==
2)
#женатые трудоустроенные мужчины
male_employed_married<-sum(married$job == 1&married$sex == 1)
#неженатые трудоустроенные мужчины
male_employed_not_married<-sum(not_married$job == 1&not_married$sex == 1)

```

```

# проверка гипотезы для подгруппы женщины

#  $\pi_1$  - доля трудоустроенных женщин среди замужних женщин
#  $\pi_2$  - доля трудоустроенных женщин среди незамужних женщин

#H0:  $\pi_1 = \pi_2$ 
#H1:  $\pi_1 \neq \pi_2$ 

# Расчет доли трудоустроенных женщин среди замужних женщин ( $p_1$ )
p1<-female_employed_married/female_married
# Расчет доли трудоустроенных женщин среди незамужних женщин ( $p_2$ )
p2<-female_employed_not_married/female_not_married

# Расчет Z-статистики
#  $\pi_1 - \pi_2 = 0$ 
p<-(female_employed_married+female_employed_not_married)/(female_married+
female_not_married)

Z_stat<-
((p1-p2)-0)/sqrt((p*(1-p)*(1/female_married+1/female_not_married)))
Z_stat
Z_critical<-c(
  "10%" = qnorm(1 - 0.10/2),
  "5%" = qnorm(1 - 0.05/2),
  "1%" = qnorm(1 - 0.01/2)
)

results<-data.frame(
  Уровень = names(Z_critical),
  Z_критическое = Z_critical,
  Z_статистика=Z_stat,
  Отклоняем_H0 = abs(Z_stat)>Z_critical
)

print(results)

```

```
> print(results)
      Уровень Z_критическое Z_статистика Отклоняем_H0
10%      10%      1.644854    -2.932265      TRUE
5%       5%      1.959964    -2.932265      TRUE
1%       1%      2.575829    -2.932265      TRUE
```

```
#Визуализация
library(ggplot2)
#параметры текста

Z_critical<-c(1.645, 1.96, 2.576)
#создаем график
ggplot(data.frame(x=c(-3.5, 3.5)), aes(x)) +
  #Основное распределение
  stat_function(fun=dnorm, args=list(mean=0, sd=1),
               size=1.2, color="gray40")+
  #критические области закрашены красным
  geom_area(stat="function", fun=dnorm,
            args=list(mean=0, sd=1),
            xlim=c(Z_critical[1], 3.5), fill="red",
            alpha=0.3
  )+
  geom_area(stat="function", fun=dnorm,
            args=list(mean=0, sd=1),
            xlim=c(-3.5, -Z_critical[1]), fill="red",
            alpha=0.3
  )+
  #вертикальные линии для критических значений
  geom_vline(xintercept=c(-Z_critical, Z_critical),
             color="red", linetype="dashed", size=0.8)+


  #линия Z-статистики
  geom_vline(xintercept=Z_stat, color="blue", size=1) +

  #подписи
  annotate("text", x=0, y=0.2, label="π1=π2", size=5)+
  geom_text(aes(x=Z_stat, y=0.1, label =paste0("Z_stat = ", round(Z_stat,
3))),
            hjust = -0.1, vjust=-1, color ="blue", size =4)+

  #Подписи уровней значимости
  geom_text(aes(x=Z_critical[1]+0.1, y = 0.3, label="10%"),
            color="red", size=3.5, hjust=1)+
  geom_text(aes(x=Z_critical[2]+0.1, y = 0.3, label="5%"),
            color="red", size=3.5, hjust=1)+
  geom_text(aes(x=Z_critical[3]+0.1, y = 0.3, label="1%"),
            color="red", size=3.5, hjust=1)+
```

```
#оформление
labs(title = "Проверка гипотезы  $\pi_1=\pi_2$ ",
      subtitle = "Красные зоны - критические области, синяя линия -
наблюдаемое значение",
      x="Z-статистика")
)+
theme_minimal(base_size = 14)+
theme(axis.text.y = element_blank(),
      axis.ticks = element_blank())
```

График 10. Проверка гипотезы о равенстве долей для женщин



Решение: гипотеза о равенстве долей трудоустроенных женщин среди замужних и незамужних отвергается на всех уровнях значимости.

Вывод: семейный статус влияет на занятость женщин. С социальной точки зрения это может означать, что незамужние женщины чаще имеют работу чем замужние, т.к. доля трудоустроенных среди незамужних больше, чем среди замужних.

```
> p1
[1] 0.6650579
> p2
[1] 0.7321429
```

```
# проверка гипотезы для подгруппы мужчины
```

```

# п1 - доля трудоустроенных мужчин среди женатых мужчин
# п2 - доля трудоустроенных мужчин среди неженатых мужчин

#H0: п1 = п2
#H1: п1 != п2

# Расчет доли трудоустроенных мужчин среди женатых мужчин (p1)
p1<-male_employed_married/male_married
# Расчет доли трудоустроенных мужчин среди неженатых мужчин (p2)
p2<-male_employed_not_married/male_not_married

# Расчет Z-статистики
# п1-п2=0
p<-(male_employed_married+male_employed_not_married)/(male_married+male_n
ot_married)

Z_stat<- ((p1-p2)-0)/sqrt((p*(1-p)*(1/male_married+1/male_not_married)))
Z_stat
Z_critical<-c(
  "10%" = qnorm(1 - 0.10/2),
  "5%" = qnorm(1 - 0.05/2),
  "1%" = qnorm(1 - 0.01/2)
)

results<-data.frame(
  Уровень = names(Z_critical),
  Z_критическое = Z_critical,
  Z_статистика=Z_stat,
  Отклоняем_H0 = abs(Z_stat)>Z_critical
)

print(results)

```

```

> print(results)
      Уровень Z_критическое Z_статистика Отклоняем_H0
10%      10%      1.644854      7.185194      TRUE
5%       5%      1.959964      7.185194      TRUE
1%       1%      2.575829      7.185194      TRUE

```

```

#Визуализация
library(ggplot2)
#параметры текста

Z_critical<-c(1.645, 1.96, 2.576)
#создаем график
ggplot(data.frame(x=c(-3.5, 3.5)), aes(x)) +
  #Основное распределение
  stat_function(fun=dnorm, args=list(mean=0, sd=1),

```

```

        size=1.2, color="gray40")+
#критические области закрашены красным
geom_area(stat="function", fun=dnorm,
          args=list(mean=0, sd=1),
          xlim=c(Z_critical[1], 3.5), fill="red",
          alpha=0.3
)+
geom_area(stat="function", fun=dnorm,
          args=list(mean=0, sd=1),
          xlim=c(-3.5, -Z_critical[1]), fill="red",
          alpha=0.3
)+
#вертикальные линии для критических значений
geom_vline(xintercept=c(-Z_critical, Z_critical),
           color="red", linetype="dashed", size=0.8)+

#линия Z-статистики
geom_vline(xintercept=Z_stat, color="blue", size=1) +


#подписи
annotate("text", x=0, y=0.2, label="π1=π2", size=5)+
geom_text(aes(x=Z_stat, y=0.1, label =paste0("Z_stat = ", round(Z_stat,
3))),
          hjust = 1, vjust=1, color ="blue", size =4)+

#Подписи уровней значимости
geom_text(aes(x=Z_critical[1]+0.1, y = 0.3, label="10%"),
          color="red", size=3.5, hjust=1)+
geom_text(aes(x=Z_critical[2]+0.1, y = 0.3, label="5%"),
          color="red", size=3.5, hjust=1)+
geom_text(aes(x=Z_critical[3]+0.1, y = 0.3, label="1%"),
          color="red", size=3.5, hjust=1)+

#оформление
labs(title = "Проверка гипотезы π1=π2",
      subtitle = "Красные зоны - критические области, синяя линия -
наблюдаемое значение",
      x="Z-статистика"
)+
theme_minimal(base_size = 14)+
theme(axis.text.y = element_blank(),
      axis.ticks = element_blank())

```

График 11. Проверка гипотезы о равенстве долей для мужчин



Решение: гипотеза о равенстве долей, трудоустроенных среди женатых и неженатых мужчин, отвергается на всех уровнях значимости.

Вывод: семейный статус влияет на занятость мужчин. С социальной точки зрения это может означать, что женатые мужчины чаще имеют работу чем неженатые, т.к. доля трудоустроенных среди женатых больше, чем среди неженатых.

1. Эффекты для мужчин и женщин различаются. Среди женщин, доля трудоустроенных больше у неженатых. У мужчин, наоборот, у женатых. Из-за этого в подгруппах гипотеза о равенстве отвергается, но без выделения этих подгрупп гипотеза не отвергается на уровнях значимости 1% и 5% за счет того, что различия в значениях у двух подгрупп компенсируются друг другом.
2. Возможные причины различий:
 - 1) Культурные: в обществе существуют стереотипы о том, что мужчина должен работать практически в любом случае, а женщина может полагаться на мужчину и не работать. Помимо этого, в некоторых религиях (например, мусульманская) может осуждаться ситуация, когда женатая женщина работает, а женатый мужчина не работает.
 - 2) Гендерные роли/ожидания со стороны семьи: в обществе на протяжении многих лет было принято, что женщина должна заботиться о детях и быте, а мужчина обеспечивать семью. Поэтому замужние женщины реже имеют работу, чтобы

заботиться о семье, а женатые мужчины чаще имеют работу тоже, чтобы заботиться о семье.

- 3) Экономические/ожидания со стороны работодателей: работодатели ожидают, что работник сможет выполнять все свои обязанности в полном объеме. Замужние женщины часто выходят в декрет и не могут работать в полном объеме. Женатые мужчины больше выкладываются на работе, т.к. они должны заботиться не только о себе, но и о семье.

Задание 4. До и после: здоровье и пандемия

Исследовательский вопрос: Изменилась ли самооценка здоровья (или другое состояние) после пандемии COVID-19?

1. **Выбор показателя.** Выберите одну переменную из RLMS-HSE, связанную со здоровьем, стрессом, настроением, уровнем энергии, частотой обращений к врачу и пр. (например, самооценка состояния здоровья, депрессия, беспокойство, хронические болезни и т.д.). В RLMS-HSE масса вопросов о здоровье. Выберите то, что интересно именно вам.

2. **Выбор волн RLMS.**

- Найдите одну волну до пандемии (например, 2017 год) и одну волну после пандемии (например, 2021 или 2022).
- Выберите только тех людей, которые участвовали в обеих волнах (панельные наблюдения).
- Перенесите все данные в R: пол, возраст, выбранный показатель здоровья.

Для анализа нами была выбрана волна 26 (2017 год), в качестве волны до пандемии, и волна 31 (2022 год), как волна после пандемии. Были взяты данные репрезентативной выборки по индивидам IBM SPSS из базы данных RLMS-HSE.

```
# открываем файлы статистики по выбранным волнам  
  
library(haven)  
path = file.path("C:/", "Users/user/Downloads", "r31i_os_75.sav")  
dataset_2022 = read_sav(path)  
  
library(haven)  
path = file.path("C:/", "Users/user/Downloads", "r26i_os_74.sav")  
dataset_2017 = read_sav(path)
```

Исследовательский вопрос: «Изменился ли ИМТ после пандемии COVID-19 для людей, чей показатель исходно был выше нормы?»

В качестве анализируемого показателя нами был выбран ИМТ (индекс массы тела). ИМТ – это простой числовой показатель, позволяющий оценить соответствие веса человека его росту.

Рассчитывается по формуле:

$$\text{ИМТ} = \frac{\text{вес (кг)}}{\text{рост (м)}^2}$$

Таким образом, для дальнейшего анализа нам необходимы рост и вес респондентов. Помимо этого добавляем уникальный ID для определения участников обеих волн, а также пол и возраст для тестирования более узких гипотез.

```
# по каждой волне отдельно создаем новые дата фреймы, содержащие только
# необходимые нам показатели: единый по всем волнам ID респондента, пол,
# рост, вес и возраст
df_2022 <- data.frame(id17 = dataset_2022$idind, height_sm_2022 =
dataset_2022$aam2, weight_kg_2022 = dataset_2022$aam1, sex =
dataset_2022$aah5, age_2022 = dataset_2022$aa_age)

df_2017 <- data.frame(id17 = dataset_2017$idind, height_sm_2017 =
dataset_2017$vm2, weight_kg_2017 = dataset_2017$vm1, sex =
dataset_2017$vh5, age_2017 = dataset_2017$v_age)

options(scipen = 999) # запрещает экспоненциальный формат для больших
чисел
options(digits = 10) # увеличивает кол-во отображаемых знаков
# при помощи функции merged объединяем дата фреймы по параметру ID,
таким образом получаем дата фрейм по респондентам, которые участвовали в
обеих волнах
merged_df <- merge(df_2017, df_2022, by = "id17")

# меняем номера столбцов, для более наглядного представления данных
merged_df <- merged_df[, c(1,4,5,9,2,3,6,7)]

# чистим дата фрейм от данных, полученных при отказе респондента отвечать
на вопрос, также для точности интерпретации, полученных при дальнейшем
анализе, результатов оставляем в выборке только респондентов возрастом от
18 лет
clean_df <- merged_df[merged_df$height_sm_2017 <= 300 &
merged_df$weight_kg_2017 <= 300 & merged_df$height_sm_2022 <= 300 &
merged_df$weight_kg_2022 <= 300 & merged_df$age_2017 >= 18, ]
# добавляем колонки по каждому году с ИМТ, рассчитанным по ранее
указанной формуле
clean_df$bmi_2017 <-
clean_df$weight_kg_2017/((clean_df$height_sm_2017/100)^2)
clean_df$bmi_2022 <-
clean_df$weight_kg_2022/((clean_df$height_sm_2022/100)^2)
```

Для удобства интерпретации добавляем колонку с расшифровкой согласно следующей таблице:

Таблица 1. Классификация ИМТ

ИМТ	Классификация
16 и менее	Выраженный дефицит массы тела
16–18,5	Недостаточная (дефицит) масса тела
18,5–24,99	Норма
25–30	Избыточная масса тела (предожирение)
30–35	Ожирение первой степени
35–40	Ожирение второй степени
40 и более	Ожирение третьей степени (морбидное)

```
clean_df$nom_2017 <- ifelse(clean_df$bmi_2017 < 18.5, "Ниже нормы",
                           ifelse(clean_df$bmi_2017 < 25.0,
                                   "Норма", "Выше нормы"))
clean_df$nom_2022 <- ifelse(clean_df$bmi_2022 < 18.5, "Ниже нормы",
                           ifelse(clean_df$bmi_2022 < 25.0,
                                   "Норма", "Выше нормы"))
```

3. Создание переменной разности.

- Для каждого индивида рассчитайте разность значений выбранного показателя: $d_i = x_{i,\text{после}} - x_{i,\text{до}}$.
- Это превратит вашу задачу в анализ зависимых (paired) выборок.

```
# создаем колонку с переменной разности
clean_df$d <- (clean_df$bmi_2022 - clean_df$bmi_2017)

# для однозначной интерпретации данных оставляем только тех респондентов,
чей показатель ИМТ изначально был выше нормы
df_final <- clean_df[clean_df$bmi_2017 > 25.0, ]
```

4. Построение доверительного интервала.

- Постройте доверительный интервал для среднего изменения μ_d для уровней значимости 90%, 95%, 99%.
- Интерпретируйте результат: ухудшилось ли в среднем состояние по этому показателю после пандемии?

```
n <- length(df_final$d)      # Количество наблюдений
mean_d <- mean(df_final$d)   # Среднее значение изменений
sd_d <- sd(df_final$d)       # Стандартное отклонение изменений
```

```

se_d <- sd_d / sqrt(n)      # Стандартная ошибка среднего

conf_levels <- c(0.90, 0.95, 0.99) # Уровни доверия 90%, 95%, 99%

calculate_z_ci <- function(alpha) {
  z_critical <- qnorm(1 - (1 - alpha)/2) # z-критическое значение
  margin_error <- z_critical * se_d # Предельная ошибка
  ci_lower <- mean_d - margin_error # Нижняя граница интервала
  ci_upper <- mean_d + margin_error # Верхняя граница интервала
  return(c(ci_lower, ci_upper))
}

z_ci_results <- sapply(conf_levels, calculate_z_ci)
colnames(z_ci_results) <- paste0(conf_levels * 100, "%")
library(ggplot2)
ci_data <- data.frame(
  Level = c("90%", "95%", "99%"),
  Lower = z_ci_results[1, ],
  Upper = z_ci_results[2, ]
)

ggplot(ci_data, aes(x = Level, y = mean_d)) +
  geom_point(size = 3) +
  geom_errorbar(aes(ymin = Lower, ymax = Upper), width = 0.1, color =
"blue2") +
  labs(title = "Доверительные интервалы (z-интервал) для среднего d",
y = "Среднее значение d", x = "Уровень доверия")

print("Доверительные интервалы (z-интервал) для среднего d:")
print(z_ci_results)

```


```

[1] "Доверительные интервалы (z-интервал) для среднего d:"
> print(z_ci_results)
      90%      95%      99%
[1,] -0.25610476 -0.27131390 -0.30103929
[2,] -0.09732357 -0.08211444 -0.05238905

```

Все доверительные интервалы (90%, 95%, 99%) полностью находятся в отрицательной области. Это означает, что среднее изменение показателя отрицательное на всех уровнях значимости. Следовательно, состояние здоровья по данному показателю в среднем улучшилось после пандемии, так как ИМТ людей, у которых до пандемии показатель был повышен, уменьшился.

График 12. Доверительные интервалы



5. Проверка гипотезы о средних изменениях здоровья по выбранному показателю. Проведите полный 5-этапный анализ:

1. Формулировка гипотез:

$$H_0 : \mu_d = 0 \quad \text{vs.} \quad H_1 : \mu_d \neq 0$$

2. Выбор и расчет тестовой статистики.
3. Для уровней значимости $\alpha = 0,10, 0,05, 0,01$ рассчитайте критическое значение.
4. Сравните значение тестовой статистики с критическим значением. Примите решение: отклоняется ли нулевая гипотеза (для каждого уровня значимости)?
5. Проинтерпретируйте полученный результат.

#проверяем гипотезу: после COVID-19 ИМТ остался неизменным

#H0: $\mu = 0$

#H1: $\mu \neq 0$

```

d <- df_final$d

# 1. Параметры теста
mu <- 0 # Гипотетическое среднее ( $H_0: \mu = 0$ )
n <- length(d) # Объем выборки
mean_d <- mean(d) # Среднее изменение
sd_d <- sd(d) # Стандартное отклонение (исправлено: убрано
деление на n-1)
se_d <- sd_d/sqrt(n) # Стандартная ошибка среднего

# 2. Расчет z-статистики
z_stat <- (mean_d - mu)/se_d

# 3. Критические значения для двустороннего теста
z_critical <- c(
  "10%" = qnorm(1 - 0.10/2),
  "5%" = qnorm(1 - 0.05/2),
  "1%" = qnorm(1 - 0.01/2)
)

# 4. Проверка гипотез
results <- data.frame(
  Уровень = names(z_critical),
  z_критическое = z_critical,
  z_статистика = z_stat,
  Отклоняем_ $H_0$  = abs(z_stat) > z_critical
)

# 5. Визуализация
library(ggplot2)
# Параметры теста
z <- z_stat
z_critical <- c(1.645, 1.96, 2.576) # Для 10%, 5%, 1%
# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
    size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(-3.5, -z_critical[1]), fill = "red", alpha = 0.3) +
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(z_critical[1], 3.5), fill = "red", alpha = 0.3) +

  # Вертикальные линии для критических значений
  geom_vline(xintercept = c(-z_critical, z_critical),
    color = "red", linetype = "dashed", size = 0.8) +

  # Линия z-статистики
  geom_vline(xintercept = z, color = "blue", size = 1) +

  # Подписи
  annotate("text", x = 0, y = 0.2, label = " $H_0: \mu = 0$ ", size = 5) +

```

```

geom_text(aes(x = z, y = 0.1,
              label = paste0("z = ", round(z_stat, 3)),
              hjust = -0.1, vjust = -1, color = "blue", size = 4) +

# Подписи уровней значимости
geom_text(aes(x = z_critical[1] + 0.1, y = 0.3, label = "10%"),
          color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[2] + 0.1, y = 0.3, label = "5%"),
          color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[3] + 0.1, y = 0.3, label = "1%"),
          color = "red", size = 3.5, hjust = 1) +

# Оформление
labs(title = "Проверка гипотезы H0:  $\mu = 0$ ",
      subtitle = "Красные зоны - критические области, синяя линия -
наблюдаемое значение",
      x = "z-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
      axis.ticks.y = element_blank())

# Вывод результатов
print(results)


```

```

> # Вывод результатов
> print(results)
Уровень z_критическое z_статистика Отклоняем_H0
10%      10%      1.644854      -3.661251      TRUE
5%       5%      1.959964      -3.661251      TRUE
1%       1%      2.575829      -3.661251      TRUE

```

График 13. Проверка двусторонней гипотезы об отсутствии изменений ИМТ



Для того, чтобы сделать более конкретные выводы, проверим гипотезу H_0 при условии, что альтернативная гипотеза: «В среднем ИМТ после пандемии уменьшилось».

$$H_0 : \mu_d = 0 \quad \text{vs.} \quad H_1 : \mu_d < 0$$

```
#проверяем гипотезу: после COVID-19 ИМТ осталось неизменным
#H0:  $\mu = 0$ 
#H1:  $\mu < 0$ 

# 1. Критические значения для одностороннего теста
z_critical <- c(
  "10%" = -qnorm(1 - 0.10),
  "5%" = -qnorm(1 - 0.05),
  "1%" = -qnorm(1 - 0.01)
)

# 2. Проверка гипотез
results <- data.frame(
  Уровень = names(z_critical),
  z_критическое = z_critical,
  z_статистика = z_stat,
  Отклоняем_H0 = z_stat < z_critical
)

# 3. Визуализация
library(ggplot2)

# Параметры теста
z_critical <- c(-1.28, -1.64, -2.326) # Для 10%, 5%, 1%

# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
    size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(-3.5, z_critical[1]), fill = "red", alpha = 0.3) +

  # Вертикальные линии для критических значений
  geom_vline(xintercept = z_critical,
    color = "red", linetype = "dashed", size = 0.8) +

  # Линия z-статистики
  geom_vline(xintercept = z_stat, color = "blue", size = 1) +

  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu = 0$ ", size = 5) +
  geom_text(aes(x = z_stat, y = 0.1,
    label = paste0("z = ", round(z_stat, 2))),
```

```

      hjust = -0.1, vjust = -1, color = "blue", size = 4) +

# Подписи уровней значимости
geom_text(aes(x = z_critical[1] + 0.1, y = 0.3, label = "10%"),
          color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[2] + 0.1, y = 0.3, label = "5%"),
          color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[3] + 0.1, y = 0.3, label = "1%"),
          color = "red", size = 3.5, hjust = 1) +

# Оформление
labs(title = "Проверка гипотезы H0:  $\mu = 0$ ",
      subtitle = "Красные зоны - критические области, синяя линия -  
наблюдаемое значение",
      x = "z-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
      axis.ticks.y = element_blank())

# Вывод результатов
print(results)

```

```


> # Вывод результатов
> print(results)
  Уровень z_критическое z_статистика Отклоняем_H0
10%      10%   -1.281551566 -3.661251463      TRUE
5%       5%   -1.644853627 -3.661251463      TRUE
1%       1%   -2.326347874 -3.661251463      TRUE

```

График 14. Проверка односторонней гипотезы об отсутствии изменений ИМТ

Проверка гипотезы H0: $\mu = 0$

Красные зоны - критические области, синяя линия - наблюдаемое значение



4. Сравните значение тестовой статистики с критическим значением. Примите решение: отклоняется ли нулевая гипотеза (для каждого уровня значимости)?

В результате проверки, мы получили что критическое значение по нашей гипотезе по модулю превышает критические значения по всем уровням значимости при двусторонней альтернативной гипотезе, а также при левосторонней альтернативной гипотезе критическое значение по нашей гипотезе меньше критических значений по всем уровням значимости, что говорит о том, что гипотеза H_0 (ИМТ в среднем не изменилось после пандемии) отвергается на всех уровнях значимости и при двусторонней, и при левосторонней альтернативных гипотезах.

5. Проинтерпретируйте полученный результат.

Проведенный статистический анализ показал, что нулевая гипотеза H_0 о неизменности среднего значения ИМТ после перенесенного COVID-19 отвергается на всех уровнях значимости (10%, 5% и 1%). Таким образом, мы можем утверждать, что ИМТ претерпел изменения на всех уровнях значимости, причем он уменьшился.

В нашем случае мы наблюдаем отрицательное изменение среднего, что позволяет нам говорить о тенденции снижения ИМТ у людей, с изначально превышающем норму ИМТ, что, возможно, означает, что они стали заниматься спортом и следить за своим здоровьем. Таким образом получаем положительные изменения здоровья после пандемии.

Однако, возможен и негативный эффект, так как люди с излишней массой тела были более подвержены заболеванию COVID-19, снижение ИМТ может быть вызвано истощением, после перенесенного вируса COVID-19, что может иметь эффект в виде снижения веса и потери мышечной массы. В таком случае полученный результат можно трактовать, как негативные изменения здоровья.

6. Повторите анализ п.5. отдельно для мужчин и женщин, или по возрастным группам (на ваш выбор):

Мы выбрали тестировать гипотезу п.5 отдельно для мужчин и женщин.

```
#проверяем гипотезу: после COVID-19 ИМТ у женщин остался неизменным
#H0:  $\mu = 0$ 
#H1:  $\mu \neq 0$ 

df_women <- df_final[as.numeric(df_final$sex.x) == 2, ]
d_w <- df_women$d
mu <- 0 # Гипотетическое среднее (H0:  $\mu = 0$ )
n_w <- length(d_w) # Объем выборки
mean_d_w <- mean(d_w) # Среднее изменение
```

```

sd_d_w <- sd(d_w)          # Стандартное отклонение
se_d_w <- sd_d_w/sqrt(n_w) # Стандартная ошибка среднего

# 2. Расчет z-статистики
z_stat_w <- (mean_d_w - mu)/se_d_w

# 3. Критические значения для двустороннего теста
z_critical <- c(
  "10%" = qnorm(1 - 0.10/2),
  "5%" = qnorm(1 - 0.05/2),
  "1%" = qnorm(1 - 0.01/2)
)

# 4. Проверка гипотез
results_w <- data.frame(
  Уровень = names(z_critical),
  z_критическое = z_critical,
  z_статистика_w = z_stat_w,
  Отклоняем_H0 = abs(z_stat_w) > z_critical
)

# 5. Визуализация
library(ggplot2)

# Параметры теста
z_stat <- z_stat_w
z_critical <- c(1.645, 1.96, 2.576) # Для 10%, 5%, 1%

# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
    size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(-3.5, -z_critical[1]), fill = "magenta", alpha =
0.3) +
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(z_critical[1], 3.5), fill = "magenta", alpha = 0.3)
+

  # Вертикальные линии для критических значений
  geom_vline(xintercept = c(-z_critical, z_critical),
    color = "magenta", linetype = "dashed", size = 0.8) +

  # Линия z-статистики
  geom_vline(xintercept = z_stat, color = "red", size = 1) +

  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu = 0$ ", size = 5) +
  geom_text(aes(x = z_stat, y = 0.1,
    label = paste0("z = ", round(z_stat_w, 3))),
    hjust = -0.1, vjust = -1, color = "red", size = 4) +

```

```

# Подписи уровней значимости
geom_text(aes(x = z_critical[1] + 0.1, y = 0.3, label = "10%"),
  color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[2] + 0.1, y = 0.3, label = "5%"),
  color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[3] + 0.1, y = 0.3, label = "1%"),
  color = "red", size = 3.5, hjust = 1) +
# Оформление
labs(title = "Проверка гипотезы H0:  $\mu = 0$ ",
  subtitle = "Пурпурные зоны - критические области, красная линия -
наблюдаемое значение",
  x = "z-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
  axis.ticks.y = element_blank())


> # Вывод результатов
> print(results_w)
  Уровень z_критическое z_статистика_w Отклоняем_H0
10%      10%      1.644853627      -3.736170227      TRUE
5%       5%      1.959963985      -3.736170227      TRUE
1%       1%      2.575829304      -3.736170227      TRUE

```

График 15. Проверка двусторонней гипотезы об отсутствии изменений ИМТ у женщин

Проверка гипотезы H0: $\mu = 0$

Пурпурные зоны - критические области, красная линия - наблюдаемое значение



Для того, чтобы сделать более конкретные выводы, проверим гипотезу H0 при условии, что альтернативная гипотеза: “В среднем ИМТ у женщин после пандемии уменьшилось”.

```

#проверяем гипотезу: после COVID-19 ИМТ у женщин остался неизменным
#H0:  $\mu = 0$ 
#H1:  $\mu < 0$ 

# 1. Критические значения для одностороннего теста
z_critical <- c(
  "10%" = -qnorm(1 - 0.10),
  "5%" = -qnorm(1 - 0.05),
  "1%" = -qnorm(1 - 0.01)
)

# 2. Проверка гипотез
results_w <- data.frame(
  Уровень = names(z_critical),
  z_критическое = z_critical,
  z_статистика_w = z_stat_w,
  Отклоняем_H0 = z_stat_w < z_critical
)

# 3. Визуализация
library(ggplot2)

# Параметры теста

z_critical <- c(-1.28, -1.64, -2.326) # Для 10%, 5%, 1%

# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
    size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(-3.5, z_critical[1]), fill = "magenta", alpha = 0.3)
+

  # Вертикальные линии для критических значений
  geom_vline(xintercept = z_critical,
    color = "magenta", linetype = "dashed", size = 0.8) +

  # Линия z-статистики
  geom_vline(xintercept = z_stat_w, color = "red", size = 1) +

  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu = 0$ ", size = 5) +
  geom_text(aes(x = z_stat_w, y = 0.1,
    label = paste0("z = ", round(z_stat_w, 2))),
    hjust = -0.1, vjust = -1, color = "red", size = 4) +

  # Подписи уровней значимости
  geom_text(aes(x = z_critical[1] + 0.1, y = 0.3, label = "10%"),
    color = "red", size = 3.5, hjust = 1) +
  geom_text(aes(x = z_critical[2] + 0.1, y = 0.3, label = "5%"),

```

```

        color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[3] + 0.1, y = 0.3, label = "1%"),
        color = "red", size = 3.5, hjust = 1) +
# Оформление
labs(title = "Проверка гипотезы H0:  $\mu = 0$ ",
      subtitle = "Пурпурные зоны - критические области, красная линия -
наблюдаемое значение",
      x = "z-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
      axis.ticks.y = element_blank())

# Вывод результатов
print(results_w)

```

```


> # Вывод результатов
> print(results_w)
Уровень z_критическое z_статистика_w Отклоняем_H0
10%      10% -1.281551566 -3.736170227      TRUE
5%       5% -1.644853627 -3.736170227      TRUE
1%       1% -2.326347874 -3.736170227      TRUE

```

График 16. Проверка односторонней гипотезы об отсутствии изменений ИМТ

Проверка гипотезы H0: $\mu = 0$

Пурпурные зоны - критические области, красная линия - наблюдаемое значение



```

#проверяем гипотезу: после COVID-19 ИМТ у мужчин остался неизменным
#H0:  $\mu = 0$ 
#H1:  $\mu \neq 0$ 

df_men <- df_final[df_final$sex.x == 1, ]
d_m <- df_men$d

```

```

mu <- 0 # Гипотетическое среднее (H0:  $\mu = 0$ )
n_m <- length(d_m) # Объем выборки
mean_d_m <- mean(d_m) # Среднее изменение
sd_d_m <- sd(d_m) # Стандартное отклонение
se_d_m <- sd_d_m/sqrt(n_m) # Стандартная ошибка среднего

# 2. Расчет z-статистики
z_stat_m <- (mean_d_m - mu)/se_d_m

# 3. Критические значения для двустороннего теста
z_critical <- c(
  "10%" = qnorm(1 - 0.10/2),
  "5%" = qnorm(1 - 0.05/2),
  "1%" = qnorm(1 - 0.01/2)
)

# 4. Проверка гипотез
results_m <- data.frame(
  Уровень = names(z_critical),
  z_критическое = z_critical,
  z_статистика_w = z_stat_m,
  Отклоняем_H0 = abs(z_stat_m) > z_critical
)

# 5. Визуализация
library(ggplot2)

# Параметры теста
z_stat <- z_stat_m
z_critical <- c(1.645, 1.96, 2.576) # Для 10%, 5%, 1%
# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
    size = 1.2, color = "gray40") +
  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(-3.5, -z_critical[1]), fill = "navyblue", alpha =
0.3) +
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(z_critical[1], 3.5), fill = "navyblue", alpha = 0.3)
+
  # Вертикальные линии для критических значений
  geom_vline(xintercept = c(-z_critical, z_critical),
    color = "navyblue", linetype = "dashed", size = 0.8) +
  # Линия z-статистики
  geom_vline(xintercept = z_stat, color = "red", size = 1) +


  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu = 0$ ", size = 5) +
  geom_text(aes(x = z_stat, y = 0.1,
    label = paste0("z = ", round(z_stat_m, 3))),
    hjust = -0.1, vjust = -1, color = "red", size = 4) +

```

```
# Подписи уровней значимости
geom_text(aes(x = z_critical[1] + 0.1, y = 0.3, label = "10%"),
          color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[2] + 0.1, y = 0.3, label = "5%"),
          color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[3] + 0.1, y = 0.3, label = "1%"),
          color = "red", size = 3.5, hjust = 1) +
# Оформление
labs(title = "Проверка гипотезы Н0:  $\mu = 0$ ",
      subtitle = "Синие зоны - критические области, красная линия -
наблюдаемое значение",
      x = "z-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
      axis.ticks.y = element_blank())
# Вывод результатов
print(results_m)
```

```
> # Вывод результатов
> print(results_m)
Уровень z_критическое z_статистика_w Отклоняем_Н0
10%      10%      1.644853627      -1.0019055      FALSE
5%       5%      1.959963985      -1.0019055      FALSE
1%       1%      2.575829304      -1.0019055      FALSE
```

График 17. Проверка двусторонней гипотезы об отсутствии изменений ИМТ у мужчин



Также как и для женского пола, проверим гипотезу H_0 при условии, что альтернативная гипотеза: «В среднем ИМТ у мужчин после пандемии уменьшилось».

```

#проверяем гипотезу: после COVID-19 ИМТ у мужчин остался неизменным
#H0:  $\mu = 0$ 
#H1:  $\mu < 0$ 

# 1. Критические значения для одностороннего теста
z_critical <- c(
  "10%" = -qnorm(1 - 0.10),
  "5%" = -qnorm(1 - 0.05),
  "1%" = -qnorm(1 - 0.01)
)

# 2. Проверка гипотез
results_m <- data.frame(
  Уровень = names(z_critical),
  z_критическое = z_critical,
  z_статистика_w = z_stat_m,
  Отклоняем_H0 = z_stat_m < z_critical
)

# 3. Визуализация
library(ggplot2)

# Параметры теста

z_critical <- c(-1.28, -1.64, -2.326) # Для 10%, 5%, 1%

# Создаем график
ggplot(data.frame(x = c(-3.5, 3.5)), aes(x)) +
  # Основное распределение
  stat_function(fun = dnorm, args = list(mean = 0, sd = 1),
    size = 1.2, color = "gray40") +

  # Критические области (закрашены красным)
  geom_area(stat = "function", fun = dnorm,
    args = list(mean = 0, sd = 1),
    xlim = c(-3.5, z_critical[1]), fill = "navyblue", alpha =
0.3) +

  # Вертикальные линии для критических значений
  geom_vline(xintercept = z_critical,
    color = "navyblue", linetype = "dashed", size = 0.8) +

  # Линия z-статистики
  geom_vline(xintercept = z_stat_m, color = "red", size = 1) +

  # Подписи
  annotate("text", x = 0, y = 0.2, label = "H0:  $\mu = 0$ ", size = 5) +
  geom_text(aes(x = z_stat_m, y = 0.1,
    label = paste0("z = ", round(z_stat_m,3))),
    hjust = -0.1, vjust = -1, color = "red", size = 4) +

  # Подписи уровней значимости
  geom_text(aes(x = z_critical[1] + 0.1, y = 0.3, label = "10%"),
    color = "red", size = 3.5, hjust = 1) +
  geom_text(aes(x = z_critical[2] + 0.1, y = 0.3, label = "5%"),

```

```

        color = "red", size = 3.5, hjust = 1) +
geom_text(aes(x = z_critical[3] + 0.1, y = 0.3, label = "1%"),
        color = "red", size = 3.5, hjust = 1) +
# Оформление
labs(title = "Проверка гипотезы H0:  $\mu = 0$ ",
      subtitle = "Синие зоны - критические области, красная линия -
наблюдаемое значение",
      x = "z-статистика") +
theme_minimal(base_size = 14) +
theme(axis.text.y = element_blank(),
      axis.ticks.y = element_blank())

# Вывод результатов
print(results_m)


```

```

> # Вывод результатов
> print(results_m)
Уровень z_критическое z_статистика_w Отклоняем_H0
10%      10% -1.281551566      -1.0019055      FALSE
5%       5% -1.644853627      -1.0019055      FALSE
1%       1% -2.326347874      -1.0019055      FALSE

```

График 18. Проверка односторонней гипотезы об отсутствии изменений ИМТ у мужчин



Основываясь на результатах тестирования гипотезы, можно заметить, что у женщин гипотеза H0 (ИМТ остался неизменным) отвергается на всех уровнях значимости и при левосторонней альтернативной гипотезе, и при двусторонней альтернативной гипотезе,

в то время как у мужчин данная гипотеза наоборот не может быть отвергнута на всех уровнях значимости при двух разных альтернативных гипотезах.

У женщин гипотеза отвергается, что позволяет нам сделать вывод о наличии изменений ИМТ после COVID-19 и притом отрицательных, что говорит об уменьшении ИМТ у женщин, а следовательно наблюдаем положительные изменения здоровья.

У мужчин гипотеза не может быть опровергнута ни на одном из уровней значимости, значит мы не можем утверждать, что у представителей мужского пола, имевших избыточную массу тела до пандемии, ИМТ изменился.

Таким образом, можно сделать вывод о том, что в среднем женщины, имевшие излишнюю массу тела до пандемии, испытали большие положительные изменения нежели мужчины. Однако не стоит забывать о возможности, упомянутой ранее, трактовки таких изменений, как результата ухудшения здоровья.

- Обсудите возможные причины: работа на удалёнке, страх за здоровье, изоляция и т.д.

Полученные данные о динамике ИМТ в период пандемии показывают статистически значимые различия между мужчинами и женщинами с исходной избыточной массой тела. Однако в отсутствие подтвержденных данных о перенесенном COVID-19 эти различия нельзя однозначно связывать именно с последствиями коронавирусной инфекции. Наблюдаемые изменения могли быть вызваны множеством других факторов, связанных с условиями жизни в период пандемии: переход на удаленную работу, снижение физической активности, изменения в режиме питания, психологический стресс, самоизоляция и карантинные ограничения.

Разницу результатов, полученных при проверке гипотез, можно обосновать тем, что женщины, возможно, более строго соблюдали ограничительные меры, активнее меняли пищевые привычки, иначе переживали стресс. Все это могло сказаться на динамике ИМТ.

7. Визуализируйте распределение изменений (гистограмма, boxplot), добавьте комментарии.

```
library(ggplot2)

# Создаем факторную переменную для пола
df_final$sex_label <- factor(df_final$sex.x,
                             levels = c(1, 2),
                             labels = c("Мужчины", "Женщины"))

# Рассчитываем статистики для аннотаций
stats_df <- df_final %>%
```

```

group_by(sex_label) %>%
summarise(
  mean = mean(d, na.rm = TRUE),
  q1 = quantile(d, 0.25, na.rm = TRUE),
  q3 = quantile(d, 0.75, na.rm = TRUE),
  iqr = IQR(d, na.rm = TRUE),
  upper_whisker = min(max(d), q3 + 1.5*iqr),
  lower_whisker = max(min(d), q1 - 1.5*iqr),
  n = n(),
  n_outliers = sum(d < q1 - 1.5*iqr | d > q3 + 1.5*iqr, na.rm = TRUE)
)

# Boxplot с аннотациями
ggplot(df_final, aes(x = sex_label, y = d, fill = sex_label)) +
  geom_boxplot(
    alpha = 0.7,
    outlier.color = "red",          # Цвет выбросов
    outlier.shape = 8,              # Форма выбросов (звездочка)
    outlier.size = 2                # Размер выбросов
  ) +
  # Линия нулевого изменения
  geom_hline(yintercept = 0, linetype = "dashed", color = "red",
linewidth = 0.8) +
  # Средние значения (зеленые треугольники)
  geom_point(data = stats_df,
    aes(x = sex_label, y = mean),
    shape = 17, size = 3, color = "darkgreen") +
  # Подписи для среднего
  geom_text(data = stats_df,
    aes(x = sex_label, y = mean,
      label = sprintf("Ср.: %.2f", mean)),
    vjust = -1.5, size = 3.5, color = "darkgreen") +
  # Подписи для квартилей
  geom_text(data = stats_df,
    aes(x = sex_label, y = q1,
      label = sprintf("Q1: %.2f", q1)),
    vjust = 1.5, size = 3, color = "blue") +
  geom_text(data = stats_df,
    aes(x = sex_label, y = q3,
      label = sprintf("Q3: %.2f", q3)),
    vjust = -1, size = 3, color = "blue") +
  # Подписи для выбросов
  scale_fill_manual(values = c("Мужчины" = "#5B9BD5", "Женщины" =
"#FF99CC")) +
  labs(title = "Изменение ИМТ после COVID-19 по полу",
    x = NULL,
    y = "Изменение ИМТ"
  ) +
  theme_minimal(base_size = 14) +
  theme(legend.position = "none",
    panel.grid.major.x = element_blank(),
    plot.title = element_text(face = "bold"),
    plot.caption = element_text(hjust = 0, size = 10)) +
  # Информация о размере выборки
  geom_text(data = stats_df,


```

```

aes(x = sex_label, y = lower_whisker,
    label = paste0("n = ", n)),
vjust = 1.5, size = 4)

```

График 19. Боксплот изменений ИМТ по полу



```

install.packages("dplyr")
library(ggplot2)
library(dplyr)

# Создаем объединенный датафрейм с метками пола
df_plot <- bind_rows(
  data.frame(Group = "Женщины", d = d_w),
  data.frame(Group = "Мужчины", d = d_m)
)

# Строим гистограмму с наложением
ggplot(df_plot, aes(x = d, fill = Group)) +
  geom_histogram(aes(y = ..density..),
    position = "identity",
    alpha = 0.5,
    bins = 30,
    color = "black") +
  scale_fill_manual(values = c("Женщины" = "magenta", "Мужчины" =
"lightblue3")) +
  labs(title = "Распределение изменений ИМТ после COVID-19",


```

```

subtitle = "Сравнение мужчин и женщин",
x = "Изменение ИМТ (кг/м²)",
y = "Плотность распределения",
fill = "Группа") +
theme_minimal(base_size = 14) +
theme(legend.position = "top")

```

График 20. Наложенная гистограмма изменений ИМТ по полу



Сравнивая боксплоты изменения ИМТ после пандемии мужчин и женщин, можно заметить, что межквартильный размах женщин больше, чем у мужчин, что указывает на то, что у представителей мужского пола меньшая вариативность изменений ИМТ.

Это же подтверждает и гистограмма распределения, на которой видно, что значения изменения ИМТ у мужчин находятся в пределах от -10 до 10, у женщин интервал значений больше. Также, на гистограмме у женщин замечен более длинный "левый хвост", что означает изменение ИМТ смещено в сторону снижения, в то время как у мужчин хвосты короче и центр распределения более симметричен относительно нуля, что говорит о том, что представители мужского пола меньше подверглись изменению ИМТ после пандемии, чем женщины.

Таким образом, на обоих графиках можно наблюдать, что динамика изменения ИМТ у женщин более выражена по сравнению с мужчинами, что мы подтвердили при проверке гипотез ранее.

```

library(ggplot2)
library(dplyr)

```

```


# Рассчитываем статистики для всей выборки
stats_all <- df_final %>%
  summarise(
    median = median(d, na.rm = TRUE),
    mean = mean(d, na.rm = TRUE),
    q1 = quantile(d, 0.25, na.rm = TRUE),
    q3 = quantile(d, 0.75, na.rm = TRUE),
    lower_whisker = max(min(d), q1 - 1.5*IQR(d)),
    upper_whisker = min(max(d), q3 + 1.5*IQR(d)),
    n = n()
  )
# Узкий боксплот для всей выборки с аннотациями
ggplot(df_final, aes(x = "", y = d)) +
  # Основной боксплот (уже)
  geom_boxplot(
    fill = "#6BAED6",
    width = 0.6,
    alpha = 0.7,
    outlier.shape = 8,
    outlier.size = 2,
    outlier.color = "red"
  ) +
  # Подписи квартилей
  geom_text(data = stats_all,
    aes(x = "", y = q1,
      label = sprintf("Q1: %.2f", q1)),
    vjust = 1.5, size = 3.2, color = "blue4") +
  geom_text(data = stats_all,
    aes(x = "", y = q3,
      label = sprintf("Q3: %.2f", q3)),
    vjust = -0.8, size = 3.2, color = "blue4") +
  # Размер выборки
  geom_text(data = stats_all,
    aes(x = "", y = upper_whisker,
      label = paste0("n=", n)),
    vjust = 2.2, size = 3.5, color = "black") +
  # Среднее значение (точка + подпись)
  geom_point(data = stats_all,
    aes(y = mean),
    shape = 17, size = 3, color = "darkgreen") +
  geom_text(data = stats_all,
    aes(x = "", y = mean,
      label = sprintf("Cp.: %.2f", mean)),
    vjust = -1, size = 3.5, color = "darkgreen") +
  # Оформление
  labs(title = "Изменение ИМТ после COVID-19 (вся выборка)",
    x = NULL,
    y = "ΔИМТ (кг/м²)",
  ) +
  theme_minimal(base_size = 14) +
  theme(legend.position = "none",
    panel.grid.major.x = element_blank(),
    plot.title = element_text(face = "bold"),
    plot.subtitle = element_text(size = 11),
    plot.caption = element_text(hjust = 0, size = 10, color =

```

```
"gray30"),
  axis.text.x = element_blank()) + # Убираем подпись по оси X
  coord_cartesian(ylim = c(min(df_final$d, na.rm = TRUE)*1.05,
                             max(df_final$d, na.rm = TRUE)*1.05)
  )
```


График 21. Боксплот изменений ИМТ

Изменение ИМТ после COVID-19 (вся выборка)



```
# Гистограмма плотности распределения
ggplot(data.frame(d = d), aes(x = d)) +
  geom_histogram(aes(y = ..density..),
    bins = 30,
    fill = "lightblue",
    color = "black",
    alpha = 0.7) +
  labs(
    title = "Распределение изменений ИМТ после COVID-19",
    x = "ΔИМТ (кг/м²)",
    y = "Плотность распределения"
  ) +
  theme_minimal(base_size = 14)
```

График 22. Гистограмма изменений ИМТ



Анализируя гистограмму распределения всей выборки, видно, что распределение близко к нормальному и имеет моду в нуле, однако заметим, что левый ус существенно длиннее правого. Таким образом, ИМТ многих респондентов не изменился, однако, среди тех, чей ИМТ претерпел изменения, у большинства ИМТ уменьшился. Более того, рассматривая боксплот, видим, что большинство значений выборки находятся в пределах от -1,5 до 1,23, что подтверждает, что изменения в большей степени отрицательные.

Источники:

1. «Российский мониторинг экономического положения и здоровья населения НИУ ВШЭ (RLMS HSE)», проводимый Национальным исследовательским университетом "Высшая школа экономики" и ООО «Демоскоп» при участии Центра народонаселения Университета Северной Каролины в Чапел Хилле и Института социологии Федерального научно-исследовательского социологического центра РАН. (Сайты обследования RLMS HSE: <http://www.hse.ru/rlms> и <https://rlms-hse.cpc.unc.edu>)».
2. Лишь половина россиян предпенсионного и пенсионного возраста пользуются интернетом // Интерфакс URL: <https://www.interfax.ru/russia/1015680> (дата обращения: 27.05.25).
3. Россиянам опровергли популярный стереотип об интернете // Лента URL: <https://lenta.ru/news/2023/10/17/stereotype/> (дата обращения: 27.05.25).
4. Индекс массы тела // Invitro URL: <https://www.invitro.md/ru/bmi> (дата обращения: 28.05.25).